
Nantes université - M2-IS

stage de fin d'étude

Echantillonnage "space filling" de l'ensemble des nuages de points

Loïck DIENER

Septembre 2026

Tuteur :
Julien Pelamatti
Merlin Keller

Référent universitaire :
Anne Philippe

Remerciements

Avant toute chose, je tiens à adresser mes plus sincères remerciements à Julien Pelamatti et Merlin Keller pour leur accompagnement, leur disponibilité et la confiance qu'ils m'ont accordée tout au long de ce stage. Leurs conseils, leur expertise et leurs encouragements m'ont été d'une aide précieuse et ont grandement contribué à la réalisation de ce travail. Je les remercie tout particulièrement pour le temps qu'ils ont consacré à la relecture attentive de ce rapport et pour la qualité de leurs remarques, qui ont permis de l'améliorer significativement.

Je souhaite également remercier l'ensemble de l'équipe P17 pour son accueil chaleureux et sa bienveillance. Grâce à eux, j'ai eu la chance d'évoluer dans un environnement de travail aussi agréable que stimulant, faisant de ce stage une expérience particulièrement enrichissante et formatrice. Je tiens notamment à remercier Emmanuel Rémy pour ses départs à la cantine toujours aussi précis, ainsi que Magali Parrino, ma co-bureau, dont la gentillesse et la bonne humeur ont largement contribué à rendre mon intégration plus facile et plus agréable.

Enfin, je souhaite adresser mes remerciements à l'ensemble du personnel du site. Qu'il s'agisse du personnel de la cantine, des équipes de ménage, de sécurité ou de maintenance, tous ont fait preuve d'un grand professionnalisme, de réactivité et de sympathie. Leur travail, souvent discret mais indispensable, participe chaque jour au bon fonctionnement du site et à la qualité de vie de tous ceux qui y travaillent.

Summary

1	introduction	4
1.1	Présentation d'EDF R&D	4
1.2	Contexte de l'étude et problématique	4
2	Cadre théorique	6
2.1	Notions et méthodes d'échantillonnage <i>space-filling</i>	6
2.2	Distances entre nuages de points	8
2.2.1	distance de Wasserstein	8
2.2.2	Maximum Mean Discrepancy	11
2.3	Comparaison des distances considérées	12
3	Méthode d'échantillonnage	13
3.1	Echantillonnage paramétrique par LHS	13
3.2	Approches itérative	15
3.3	Méthodes d'échantillonnage multi-nuages	17
3.3.1	Gestion du cardinal des nuages	17
3.3.1.1	Approche softmax	18
3.3.1.2	Approche sigmoïde	19
3.3.2	Méthode maximin	22
3.3.3	Introduction d'un terme de répulsion	25
3.3.4	Introduction d'un paramètre de répulsion adaptative	26
3.3.5	Alternative aux approches maximines	29
4	Évaluation des méthodes proposées	32
4.1	Application au cas AMON	33
4.2	Analyse par diagrammes de persistance	34
5	Étude comparative de l'utilisation des distances MMD et Wasserstein	37
6	Conclusion et perspectives	38

Glossaire

- d : dimension dans laquelle vivent nos nuages de points
- N : nombre de nuages de points dans notre échantillon
- n : nombre de points dans un nuage de points
- $E = (X_1, \dots, X_N)$: échantillon de nuages de points
- A : espaces des nuages de points sur lequel nous cherchons notre solution
- w_i : poids associé au point i d'un nuage de points
- $W = (w_1, \dots, w_n)$: vecteur contenant les poids associés à chaque point d'un nuage
- $\mathcal{W} = (W_1, \dots, W_N)$: vecteur contenant les vecteurs de poids associés à chaque nuage
- p_i : probabilité d'activation du point i
- ρ_i : proportion d'activation du point i
- $N_{\max}$: nombre de points maximal que peut avoir un nuage de points de notre ensemble
- $N_{\min}$: nombre de points minimal que peut avoir un nuage de points de notre ensemble
- $\llbracket 1, n \rrbracket$: l'ensemble des entiers de 1 à n , $\{1, \dots, n\}$
- ϕ_{Mm} : fonction maximin
- ϕ_{mM} : fonction minimax
- $\#E$: correspond au cardinal de l'ensemble E

1 introduction

1.1 Présentation d'EDF R&D

Entreprise française leader dans le domaine de l'énergie, EDF est un ancien EPIC (Établissement Public à Caractère Industriel et Commercial) créé en 1946 et privatisé en 2004. Aujourd'hui l'activité d'EDF s'étend sur de nombreux domaines. En premier lieu, elle est chargée de l'exploitation du parc nucléaire, avec 56 réacteurs de différents niveaux de puissance répartis sur tout le territoire. L'entreprise est également tournée vers les énergies renouvelables avec un pôle qui leur est spécialement dédié. Le groupe exploite ainsi de nombreux champs éoliens terrestres et en mer mais aussi des champs solaires ainsi que des centrales hydrauliques. Cela fait de lui le premier producteur européen d'énergies renouvelables. Au total, le groupe est présent dans plus de trente pays, tant dans les domaines que sont la production et la distribution d'électricité que dans le domaine des services.

Un des centres de recherche et développement d'EDF se trouve à Chatou, dans le département des Yvelines. Ce site R&D concentre ses activités autour des domaines de la production hydraulique, nucléaire et des énergies renouvelables, notamment sur des problématiques relatives à la simulation numérique et dans le développement des méthodes d'accompagnement dans la conduite, la surveillance et le maintien des installations existantes et à venir. Il regroupe trois départements : le département MFEE (Mécanique des Fluides, Énergies et Environnement), le département LNHE (Laboratoire National d'Hydraulique et Environnement) et le département PRISME (Performance, Risque Industriel et Surveillance pour la Maintenance et l'Exploitation). Le département PRISME est constitué de 6 groupes de recherche et emploie 140 ingénieurs et techniciens, dont les travaux couvrent l'intégralité du cycle de la donnée pour les moyens de production d'électricité. Grâce à ses compétences variées (data science, IA, IoT, simulation, etc.) et sa connaissance métier, il propose des solutions innovantes pour comprendre, surveiller, prédire et optimiser le fonctionnement de ces moyens.

Au sein du département PRISME, le groupe P17 Gestion d'Actifs, Incertitudes et Apprentissage statistique (GAIA) rassemble une vingtaine d'ingénieurs-chercheurs. Ce groupe a pour mission de proposer des solutions innovantes pour répondre à des problèmes liés à la maîtrise des risques, l'amélioration de la sûreté, l'optimisation des performances technico-économiques et l'estimation de la durée de vie des matériels.

1.2 Contexte de l'étude et problématique

Les nuages de points apparaissent naturellement dans de nombreux problèmes d'ingénierie, notamment lorsque les données sont décrites par des collections d'objets géométriques dont l'ordre des éléments n'a aucune importance. De telles structures interviennent dans des domaines variés tels que l'optimisation de réseaux, la modélisation géométrique, l'analyse de formes ou encore la conception de systèmes industriels. Elles permettent de représenter des objets complexes sous la forme d'un ensemble de points dans un espace euclidien et peuvent être définies formellement comme suit :

Définition 1 (nuage de points) : On définit un nuage de points sur $\mathbb{R}^d$ par une famille finie de points de $\mathbb{R}^d$, à permutation près. Donc, soit $C = (x_1, \dots, x_n)$ tel que $\forall i \in \llbracket 1, n \rrbracket, x_i \in \mathbb{R}^d$ alors C est un nuage de points.

De plus si $C = (x_1, \dots, x_n)$ et $C' = (y_1, \dots, y_n)$ sont deux nuages de points et s'il existe une permutation σ de $\llbracket 1, n \rrbracket$ telle que $y_i = x_{\sigma(i)} \quad \forall i \in \llbracket 1, n \rrbracket$, alors C et C' désignent le même nuage de points.

Un exemple naturel est celui du positionnement des turbines au sein d'un parc éolien. Chaque configuration peut être représentée par un nuage de points dont les éléments correspondent aux coordonnées des différentes turbines. Dans ce contexte, deux configurations ne diffèrent pas lorsque seul l'ordre des turbines est modifié, ce qui illustre le caractère invariant par permutation de ce type de représentation.

L'exploration efficace d'ensembles de nuages de points nécessite la définition de représentations adaptées ainsi que le développement de stratégies d'échantillonnage capables de couvrir au mieux l'espace des configurations possibles. Cette problématique est particulièrement délicate en raison de la structure spécifique de ces objets. En effet, un nuage de points n'est pas uniquement caractérisé par la position de ses éléments ; son cardinal peut également varier d'une configuration à l'autre. Dès lors, les méthodes classiques conçues pour des espaces euclidiens de dimension fixe ne sont plus directement applicables. Afin de répondre à ces difficultés, plusieurs approches ont été proposées dans la littérature, notamment des méthodes fondées sur la théorie du transport optimal et des techniques reposant sur les noyaux. Ces outils permettent de définir des notions pertinentes de similarité entre nuages de points et ouvrent la voie à la construction d'algorithmes d'échantillonnage adaptés à ce cadre particulier. Les principales méthodes étudiées au cours de ce stage seront présentées et comparées sur différents exemples représentatifs.

L'objectif de ce stage est donc de développer une méthode de construction d'échantillons *space-filling*, noté E au sein d'un domaine compact de nuages de points, noté A , avec $E \subset A$. Nous noterons N le cardinal de E , $\#E = N$ et n le nombre de points dans un nuage.

La construction d'échantillons *space-filling* vise à répartir les configurations de manière aussi homogène que possible dans l'espace considéré afin d'en assurer une exploration efficace. Dans le cadre de ce travail, cette problématique est abordée dans l'espace des nuages de points, dont chaque élément possède une structure interne pouvant évoluer. Le problème étudié présente ainsi une double difficulté, en effet, il devient nécessaire d'optimiser simultanément la disposition géométrique des points composant chaque nuage ainsi que leur cardinal. Dans la suite, on supposera que le cardinal des nuages de points est borné. Plus précisément, les nuages considérés contiendront entre N_{min} et N_{max} points. Donc, contrairement au cas classique d'un espace vectoriel de dimension fixe, l'optimisation ne porte donc pas uniquement sur la position des variables. Elle doit également prendre en compte les modifications de structure des objets manipulés. L'algorithme recherché doit être capable de déplacer, d'ajouter ou de supprimer des points afin d'améliorer progressivement la qualité de la couverture obtenue. L'enjeu est ainsi de construire une méthode capable d'explorer efficacement un espace complexe, non linéaire et de dimension variable, tout en conservant les propriétés recherchées des plans d'expériences *space-filling*.

2 Cadre théorique

2.1 Notions et méthodes d'échantillonnage *space-filling*

Avant de présenter les méthodes développées au cours de ce stage, il convient d'introduire dans un premier temps la notion d'échantillonnage *space-filling*.

Définition 2 (échantillonnage *space-filling*) : Un échantillonnage est dit *space-filling* lorsqu'il assure une couverture aussi homogène que possible de l'espace considéré. Intuitivement, les éléments de l'échantillon doivent être répartis de manière à éviter les zones de forte concentration ainsi que les régions insuffisamment explorées.




FIGURE 1 – Comparaison entre un échantillon *space-filling* à gauche et un échantillon non *space-filling* à droite.

La FIGURE 1 illustre cette idée dans le cas de l'espace euclidien $[0, 1]^2$ avec l'échantillon de gauche qui représente une répartition homogène des points, laquelle peut être qualifiée de *space-filling*, tandis que celui de droite laisse apparaître des regroupements et des zones peu couvertes.

La construction d'échantillons *space-filling* est une problématique largement étudiée dans la littérature. De nombreux critères ont été proposés afin d'évaluer la qualité d'un échantillon et de favoriser une couverture homogène de l'espace considéré. Parmi les plus utilisés figurent les critères *maximin* et *minimax*, ainsi que les plans de type *Latin Hypercube Sampling* (LHS), étudiés notamment par Pronzato et Müller^{14;15} ou encore Joseph⁸. Ces différents critères peuvent alors se définir comme suit :

Définition 3 (*maximin*)¹⁴ : Soit $E = \{X_1, \dots, X_n\}$ un ensemble de n éléments d'un espace métrique (A, D) . Le critère maximin se définit en cherchant à maximiser

$$\phi_{Mm}(E) = \min_{i \neq j} D(X_i, X_j)$$

Il consiste donc à rechercher l'ensemble E^* maximisant cette quantité. Donc ,

$$E^* \in \operatorname{argmax}_{E \subset A, \#E=n} \phi_{Mm}(E).$$

Autrement dit, le critère maximin cherche à éloigner le plus possible la paire d'éléments la plus rapprochée de notre ensemble. Ce critère favorise donc naturellement le positionnement des éléments sur les bords de notre espace.

Définition 4 (minimax)¹⁴ : Soit $E = \{X_1, \dots, X_n\}$ un ensemble de n éléments d'un espace métrique (A, D) . Le critère minimax se définit en cherchant à minimiser

$$\phi_{mM}(E) = \max_{x \in A} \min_{i=1, \dots, n} D(x, X_i)$$

Il consiste donc à rechercher l'ensemble E^* minimisant cette quantité. Donc ,

$$E^* \in \operatorname{argmin}_{E \subset A, \#E=n} \phi_{mM}(E).$$

Le critère minimax, quant à lui, cherche à diminuer le plus possible la taille du plus grand trou que notre échantillon laisse dans l'espace.

Définition 5 (LHS)¹ : Un Latin Hypercube Sampling (LHS) ou Latin Hypercube Design (LHD) est une matrice $N \times d$ que l'on note π , dans laquelle chacune des colonnes est une permutation de l'ensemble des entiers $\{1, \dots, N\}$. Nous avons donc que chaque point x_i est défini par :

$$x_i^j = a_j + \pi(i, j) \frac{b_j - a_j}{N} + U_j^i, \quad \text{pour } 1 \leq i \leq N, 1 \leq j \leq d$$

où a_j, b_j sont respectivement la borne inférieure et la borne supérieure de la dimension j de notre espace. $U_j^i \sim \mathcal{U}\left[0, \frac{b_j - a_j}{N}\right]$ est une valeur aléatoire de distribution uniforme sur $\left[0, \frac{b_j - a_j}{N}\right]$, ce qui permet de savoir où sont placés les points dans chaque case¹.

Cela revient donc à partitionner l'espace en N^d cubes égaux et à prendre, pour chaque dimension, exactement un point par partition, que l'on tire uniformément sur celle-ci. Bien que cette méthode puisse donner de très bons résultats, elle peut également en donner de très mauvais, comme on peut le voir sur la FIGURE 2. En revanche, une méthode communément optimisée est la méthode dite de LHS optimisé qui consiste alors à effectuer un grand nombre de tirage LHS et de ne conserver uniquement celui ayant, dans notre cas, la plus grande distance minimal entre deux points de celui-ci.

Au vu de la complexité d'implémentation et du coût computationnel du critère minimax, qui nécessite l'exploration de l'ensemble du domaine afin d'identifier la plus grande distance à l'échantillon, nous ne l'avons pas utilisé lors de ce stage. En revanche, les critères maximin ainsi que les plans de type LHS ont servi de base à la majorité des méthodes développées par la suite.




FIGURE 2 – Comparaison entre deux échantillons obtenus via un LHS (Figure inspirée de l'article Design of computer experiments⁶).

2.2 Distances entre nuages de points

La notion de *space-filling* et les approches permettant de construire de tels échantillons étant désormais présentées, il reste à adapter ces méthodes au cadre particulier des nuages de points. Une des principales difficultés que cela soulève est qu'une distance entre nuages de points est nécessaire afin de comparer les éléments de notre espace, en particulier pour l'application du critère maximin. Il convient donc de choisir une métrique capable de comparer des nuages de points dont les cardinaux peuvent être différents. Parmi les nombreuses distances existantes, nous avons retenu la distance de Wasserstein¹³ d'ordre 2 ainsi que la *Maximum Mean Discrepancy*¹² (MMD). Ces deux métriques ont été utilisées tout au long de ce stage afin d'étudier l'influence du choix de la distance sur les méthodes proposées.

2.2.1 distance de Wasserstein

Dans un premier temps, nous pouvons définir la distance de Wasserstein par :

Définition 6 (distance de Wasserstein)¹⁷ : Soient μ, ν deux mesures sur un espace métrique $(\mathcal{X}, D)$. La distance de Wasserstein à l'ordre p nous est donnée par :

$$W_p^p(\mu, \nu) = \inf_{\pi \in \Pi(\mu, \nu)} \int_{\mathcal{X} \times \mathcal{X}} D(x, x')^p d\pi(x, x')$$

- $D(x, x')$ la distance Euclidienne entre x et x' sur $\mathcal{X}$
- $\Pi(\mu, \nu)$ est l'ensemble des mesures de probabilité sur $\mathcal{X} \times \mathcal{X}$ ayant pour marginales μ et ν

Bien que la définition précédente soit formulée dans un cadre général, nous ne nous intéressons ici qu'à son application aux nuages de points. Ces derniers peuvent être interprétés comme

des mesures empiriques discrètes. Dans ce contexte particulier, la distance de Wasserstein admet une formulation plus concrète, donnée ci-dessous.

Définition 7 (distance de Wasserstein)¹⁷ : Soient $\alpha = \sum_{i=1}^n a_i \delta_{x_i}$, $\beta = \sum_{i=1}^m b_i \delta_{y_i}$ deux mesures de probabilité discrètes. La distance de Wasserstein à l'ordre p dans un contexte discret nous est donné par :

$$W_p^p(\alpha, \beta) = \min_{\gamma_{i,j} \geq 0} \sum_{i,j} \gamma_{i,j} D(x_i, y_j)^p$$

- $D(x, x')$ la distance Euclidienne entre x et x' sur X
- Sous contraintes que $\sum_j \gamma_{i,j} = a_i$ et $\sum_i \gamma_{i,j} = b_j$ et $\sum_{i,j} \gamma_{i,j} = 1$

$\gamma_{i,j}$ représente donc la quantité de masse qui est transportée de x_i à y_j

Bien que la distance de Wasserstein fournisse une mesure adaptée à la comparaison de nuages de points, son évaluation exacte nécessite la résolution d'un problème de transport optimal dont la complexité croît rapidement avec la taille des données. Afin de rendre ce calcul plus efficace, Cuturi³ propose d'introduire un terme de régularisation entropique dans le problème de transport. Cette modification conduit à la distance de Sinkhorn, ou coût de transport régularisé, qui peut être calculée efficacement à l'aide de l'algorithme de Sinkhorn¹³.

Définition 8 (coût de transport régularisé de Sinkhorn)¹³ : Soient $\alpha = \sum_{i=1}^n a_i \delta_{x_i}$ et $\beta = \sum_{j=1}^m b_j \delta_{y_j}$ deux mesures de probabilité discrètes. Le coût de transport optimal régularisé par entropie est défini par :

$$OT_\varepsilon(\alpha, \beta) = \min_{\gamma \in U(a,b)} \sum_{i,j} \gamma_{i,j} D(x_i, y_j)^p + \varepsilon \sum_{i,j} \gamma_{i,j} (\log(\gamma_{i,j}) - 1),$$

où

$$U(a, b) = \left\{ \gamma \geq 0 ; \sum_j \gamma_{i,j} = a_i \text{ et } \sum_i \gamma_{i,j} = b_j \right\}.$$

- $D(x_i, y_j)$ désigne la distance entre les points x_i et y_j ;
- $\gamma_{i,j}$ représente la quantité de masse transportée de x_i vers y_j ;
- $\varepsilon > 0$ est le paramètre de régularisation entropique.

Toutefois, cette régularisation introduit un biais. Pour obtenir une mesure de dissimilarité positive et nulle uniquement lorsque les distributions coïncident, on utilise la divergence de Sinkhorn.¹³

Définition 9 (divergence de Sinkhorn)¹³ : Soient $\alpha = \sum_{i=1}^n a_i \delta_{x_i}$ et $\beta = \sum_{j=1}^m b_j \delta_{y_j}$ deux mesures de probabilité discrètes. La divergence de Sinkhorn associée à la régularisation

entropique ε est définie par

$$S_\varepsilon(\alpha, \beta) = OT_\varepsilon(\alpha, \beta) - \frac{1}{2}OT_\varepsilon(\alpha, \alpha) - \frac{1}{2}OT_\varepsilon(\beta, \beta).$$

Cette divergence permet d'avoir les propriétés suivantes :

- $S_\varepsilon(\alpha, \beta) \geq 0$;
- $S_\varepsilon(\alpha, \alpha) = 0$;
- lorsque $\varepsilon \rightarrow 0$, $S_\varepsilon(\alpha, \beta)$ converge vers le coût de transport optimal (et donc vers la distance de Wasserstein lorsque le coût est donné par une distance métrique élevée à la puissance p).

Donc la divergence de Sinkhorn peut bien être interprétée comme une distance.

L'avantage de cette divergence par rapport à la distance de Wasserstein classique est qu'elle permet, grâce à la propriété suivante, d'obtenir une résolution efficace du problème de transport optimal. En effet, le plan de transport optimal régularisé admet une forme factorisée particulièrement simple, qui est à la base de l'algorithme de Sinkhorn.

Proposition 1: (forme du plan de transport optimal régularisé)¹³ Le plan de transport optimal γ^* solution du problème

$$\min_{\gamma \in U(a,b)} \sum_{i,j} \gamma_{i,j} D(x_i, y_j)^p + \varepsilon \sum_{i,j} \gamma_{i,j} (\log(\gamma_{i,j}) - 1)$$

, s'écrit sous la forme

$$\gamma^* = \text{diag}(u^*) K \text{diag}(v^*),$$

où $u^* \in \mathbb{R}_+^n$ et $v^* \in \mathbb{R}_+^m$ sont deux vecteurs strictement positifs et où K est la matrice définie par

$$K_{i,j} = e^{-C_{i,j}/\varepsilon},$$

avec

$$C_{i,j} = D(x_i, y_j)^p$$

la matrice de coût associée au problème de transport.

Dans cette expression :

- $\text{diag}(u^*)$ et $\text{diag}(v^*)$ désignent les matrices diagonales construites respectivement à partir de u^* et v^* ;
- $\gamma_{i,j}^*$ représente la quantité de masse transportée de x_i vers y_j .

Les vecteurs u^* et v^* sont déterminés de manière à satisfaire les contraintes de marginales $\gamma^* \mathbf{1}_m = a$ et $(\gamma^*)^T \mathbf{1}_n = b$. Ils peuvent être obtenus comme limites des suites générées par l'algorithme de Sinkhorn :

$$u^{(k+1)} = \frac{a}{K v^{(k)}} \quad v^{(k+1)} = \frac{b}{K^T u^{(k+1)}},$$

où les divisions sont effectuées composante par composante. Sous des hypothèses usuelles, ces suites convergent vers u^* et v^* .

La preuve de cette propriété peut être trouvée dans les notes de cours *Math 612 : Single Cell Analysis* de Geoffrey Schiebinger¹⁹.

Pour le reste de ce manuscrit, à chaque fois que nous parlerons de distance de Wasserstein nous aurons calculé la divergence de Sinkhorn.

2.2.2 Maximum Mean Discrepancy

Contrairement à la distance de Wasserstein, qui repose sur la résolution d'un problème de transport optimal, la MMD compare directement deux distributions de probabilité à travers leurs représentations dans un espace de Hilbert à noyau reproduisant (RKHS). Cette approche permet d'obtenir une mesure de dissimilarité simple à calculer à partir d'échantillons¹². Elle se définit de la manière suivante :

Définition 10 (Maximum Mean Discrepancy : MMD)¹² : Soient P et Q deux distributions de probabilité sur un espace $\mathcal{X}$ et $\mathcal{H}$ un espace de Hilbert à noyau reproduisant associé à un noyau k . La MMD entre P et Q peut être définie par

$$\text{MMD}^2(P, Q) = \mathbb{E}_{X, X' \sim P}[k(X, X')] + \mathbb{E}_{Y, Y' \sim Q}[k(Y, Y')] - 2\mathbb{E}_{X \sim P, Y \sim Q}[k(X, Y)].$$

- k désigne le noyau utilisé pour mesurer la similarité entre deux observations ;
- la MMD est nulle si et seulement si P et Q sont identiques lorsque le noyau k est caractéristique.

Donc pour que la MMD représente une distance, le noyau k que l'on choisie doit être caractéristique, ce qui contraint fortement le choix de celui-ci. Un noyau caractéristique peut être défini comme suit :

Définition 11 (noyau caractéristique)¹² : Un noyau k défini positif est dit caractéristique si l'application $P \mapsto \mu_P$ est injective. Sachant

$$\mu_P = \int k(x, \cdot) dP(x).$$

Comme pour la distance de Wasserstein, nous nous intéressons ici uniquement au cas des nuages de points, que l'on peut interpréter comme des distributions discrètes. Dans ce cadre particulier, la définition précédente admet une écriture plus explicite, donnée ci-dessous.

Définition 12 (MMD empirique)¹² : Soient

$$\alpha = \frac{1}{n} \sum_{i=1}^n \delta_{x_i} \quad \text{et} \quad \beta = \frac{1}{m} \sum_{j=1}^m \delta_{y_j}$$

deux mesures de probabilité discrètes associées à deux nuages de points. La MMD empirique est donnée par

$$\text{MMD}^2(\alpha, \beta) = \frac{1}{n^2} \sum_{i=1}^n \sum_{j=1}^n k(x_i, x_j) + \frac{1}{m^2} \sum_{i=1}^m \sum_{j=1}^m k(y_i, y_j) - \frac{2}{nm} \sum_{i=1}^n \sum_{j=1}^m k(x_i, y_j).$$

- $k(x_i, x_j)$ mesure la similarité entre les points x_i et x_j ;
- $k(y_i, y_j)$ mesure la similarité entre les points y_i et y_j ;
- $k(x_i, y_j)$ mesure la similarité entre le point x_i et le point y_j ;

Comme pour la distance de Wasserstein, la MMD définit effectivement une distance dès lors que le noyau utilisé est caractéristique. Dans ce travail, nous utiliserons le noyau gaussien, qui possède cette propriété. D'autres choix sont toutefois possibles, tels que les noyaux associés à l'*energy distance*, le noyau laplacien ou encore le noyau de Matérn. Bien que chacun de ces noyaux possède des propriétés différentes, nos expérimentations ont montré que le choix du noyau n'avait qu'une influence marginale sur les résultats obtenus.

La définition précédente correspond au cas où chaque point du nuage serait considéré avec le même poids. Or, certaines des méthodes développées au cours de ce stage nécessitent de représenter des distributions discrètes non uniformes. Il est donc naturel d'introduire une version pondérée de la MMD.

Soient

$$\alpha = \sum_{i=1}^n a_i \delta_{x_i} \quad \text{et} \quad \beta = \sum_{j=1}^m b_j \delta_{y_j},$$

avec

$$\sum_{i=1}^n a_i = \sum_{j=1}^m b_j = 1.$$

La MMD s'écrit alors sous la forme

$$\text{MMD}^2(\alpha, \beta) = \sum_{i=1}^n \sum_{j=1}^n a_i a_j k(x_i, x_j) + \sum_{i=1}^m \sum_{j=1}^m b_i b_j k(y_i, y_j) - 2 \sum_{i=1}^n \sum_{j=1}^m a_i b_j k(x_i, y_j).$$

En prenant $a_i = 1/n$, $\forall i \in \llbracket 1, n \rrbracket$ et $b_j = 1/m$, $\forall j \in \llbracket 1, m \rrbracket$ on retombe sur la première définition de la MMD dans le cadre discret.

2.3 Comparaison des distances considérées

Les deux distances retenues ayant désormais été présentées, il est naturel d'étudier la complémentarité des informations qu'elles fournissent dans le cadre des méthodes d'échantillonnage considérées. En effet, si la MMD et la distance de Wasserstein conduisaient systématiquement à des conclusions similaires concernant la proximité des nuages de points, alors l'utilisation de l'une ou de l'autre reviendrait essentiellement à effectuer deux analyses redondantes.

Afin d'évaluer cette hypothèse, nous avons généré, à l'aide de la méthode LHS (Section 3.1), un ensemble de 15 nuages de points (échantillon présenté en Annexe 1). Les distances ont ensuite été calculées pour chaque paire de nuages selon les deux métriques considérées, conduisant aux matrices de distances présentées en FIGURE 3.




FIGURE 3 – Comparaison des matrices de distance obtenue à l’aide de Wasserstein et de MMD

Nous observons une forte concordance entre les résultats obtenus avec la MMD et avec la distance de Wasserstein. Les groupes de nuages identifiés comme proches ou éloignés sont globalement les mêmes selon les deux métriques, ce qui indique que les principales relations de similarité entre les nuages de points sont préservées indépendamment de la distance utilisée.

Néanmoins, certaines différences locales restent visibles entre les deux matrices. Ces écarts suggèrent que la MMD et la distance de Wasserstein ne présentent pas exactement la même sensibilité aux caractéristiques des distributions comparées. Ainsi, bien qu’elles conduisent à une organisation globale similaire des données, le choix de la métrique peut influencer plus finement l’évaluation des différences entre nuages de points. Cette observation rend donc pertinente l’étude comparative de ces deux distances dans les différentes méthodes d’échantillonnage présentées dans la suite de ce travail. Chacune des méthodes seront présenté avec une seule distance utilisé pour leur construction, et la comparaison des résultat obtenue en utilisant l’une ou l’autre distance seront détailler dans la section 5.

3 Méthode d’échantillonnage

Les outils théoriques nécessaires ayant été introduits, nous pouvons désormais présenter les différentes méthodes de construction des échantillons de nuages de points. Ces méthodes seront étudiées successivement, des plus simples aux plus élaborées.

3.1 Échantillonnage paramétrique par LHS

Dans un premier temps, nous avons choisi de générer nos nuages de points à l’aide d’un plan d’expériences de type LHS. Cependant, cette méthode présente une difficulté majeure dans notre contexte. En effet, comme expliqué précédemment, le LHS repose sur un découpage préalable de l’espace d’échantillonnage en intervalles de même taille afin de garantir qu’une observation soit tirée dans chaque sous-intervalle. Une telle approche nécessite donc de connaître

précisément l'espace dans lequel les observations sont générées. Or, dans notre cas, les éléments considérés sont des nuages de points dont la cardinalité est variable, ce qui rend difficile la définition directe d'un espace sur lequel appliquer un LHS. À défaut d'une méthode permettant actuellement de réaliser un tel découpage, nous avons choisi d'appliquer le LHS non pas directement aux nuages de points, mais aux paramètres d'une loi permettant leur génération. Par ailleurs, n'ayant pas identifié de stratégie pertinente pour intégrer la cardinalité des nuages dans ce processus, le nombre de points de chaque nuage est tiré uniformément parmi les valeurs admissibles.

La loi retenue pour la génération des nuages est la loi bêta. Ce choix s'explique par le fait que nous souhaitons travailler, dans un premier temps, dans l'hypercube unité. Ainsi, la loi bêta étant défini sur l'intervalle $[0, 1]$, elle permet naturellement de générer les coordonnées de nos points dans cet espace. Chaque coordonnée de chaque dimension est ainsi tirée indépendamment selon une loi bêta. Cependant, les paramètres de cette loi appartiennent à $\mathbf{R}^+$, qui est un espace non borné et ne permet donc pas une partition uniforme de celui-ci. Nous avons donc choisi de construire notre LHS à partir de l'espérance et de la variance des lois bêta. Ces deux grandeurs appartiennent à des intervalles bornés, dépendant de la taille et de la forme de notre espace, et permettent ainsi de retrouver les paramètres de la distribution, ce qui les rend particulièrement adaptées à la mise en oeuvre de cette stratégie d'échantillonnage. Néanmoins, l'utilisation d'un LHS sur les couples $(\mathbb{E}[X], \text{Var}(X))$ ne garantit pas à elle seule une couverture satisfaisante de l'espace considéré. En effet, comme vu précédemment sur la FIGURE 2, différents arrangements d'un même LHS peuvent conduire à des répartitions plus ou moins homogènes des points. Afin d'obtenir un échantillon aussi *space-filling* que possible, nous générons un grand nombre de réalisations candidates du LHS. Pour chacune d'elles, nous calculons l'ensemble des distances entre les points de l'échantillon et retenons finalement l'arrangement maximisant la distance minimale entre deux points. Cette stratégie permet de favoriser une meilleure dispersion des couples espérance-variance dans l'espace étudié.

Cette procédure nous permet ainsi d'obtenir des échantillons de nuages de points tels que celui de la FIGURE 4.

Comme nous pouvons le constater sur cette figure, les nuages de points obtenus présentent une certaine diversité de formes. Néanmoins, ils conservent des caractéristiques propres aux nuages générés à partir de lois bêta. En particulier, on n'observe pas de structures très localisées constituées de plusieurs amas de points distincts, à l'exception des concentrations pouvant apparaître à proximité des bornes de l'intervalle $[0, 1]$, qui sont typiques de certaines paramétrisations de lois bêta.

Cette observation met en évidence une limite importante de la méthode proposée. En effet, bien que le LHS construit sur les couples $(\mathbb{E}[X], \text{Var}(X))$ garantisse une bonne répartition des paramètres des lois bêta utilisé pour générer les nuages, il ne fournit aucune garantie quant à la répartition des nuages eux-mêmes dans l'espace des nuages de points. Autrement dit, le caractère *space-filling* est assuré dans l'espace des paramètres de génération, mais pas nécessairement dans l'espace qui nous intéresse réellement.

Cette approche ne doit cependant pas être écartée pour autant. Bien que les échantillons




FIGURE 4 – Nuages de points obtenus avec la méthode LHS

ainsi obtenus soient encore loin d'être parfaitement *space-filling*, ils restent relativement bien répartis et constituent un point d'initialisation pertinent pour plusieurs des méthodes d'optimisation qui seront présentées dans la suite de ce rapport.

3.2 Approches itérative

Face aux limites observées lors de la génération d'échantillons par LHS, notamment la forte dépendance de la diversité obtenue aux lois de génération sous-jacentes, plusieurs approches itératives fondées sur un critère de type *maximin* ont été étudiées. Les développements détaillés de ces méthodes sont présentés en Annexe 2. L'objectif poursuivi était d'améliorer la couverture de l'espace de recherche en maximisant la distance minimale entre les nuages de points composant l'échantillon.

Une première approche consistait à construire l'échantillon de manière totalement séquentielle. À chaque itération, un nouveau nuage de points était recherché de façon à être aussi éloignée que possible des nuages déjà présents dans l'échantillon. Cette stratégie repose sur un critère *maximin* classique visant à maximiser la distance séparant un candidat de son plus proche voisin parmi les nuages déjà sélectionnés. Le problème d'optimisation considéré à chaque

étape s'écrit alors :

$$x^* = \arg \max_{x \in A} \min_{X_i \in E} (D(X_i, x))$$

Avec

- E l'échantillon de nuage de points
- D une distance sur les nuages de points
- x un nuage de points

La résolution de ce problème a été réalisée à l'aide de l'algorithme d'optimisation *AdamW*¹⁶. Cet optimiseur a été retenu en raison de sa robustesse sur des problèmes de grande dimension, de sa disponibilité native dans PyTorch et de sa bonne adaptation à un contexte où la dimension de l'espace d'optimisation peut varier selon les configurations étudiées. Par ailleurs, l'évaluation des fonctions objectif considérées étant particulièrement coûteuse, l'utilisation d'une méthode reposant sur les gradients présente un avantage important. Ceux-ci peuvent en effet être calculés efficacement grâce aux mécanismes de différentiation automatiques fournis par PyTorch. Les résultats préliminaires obtenus dans le cadre de ces premières expérimentations ayant montré une convergence stable ainsi que des performances satisfaisantes, *AdamW* a ensuite été conservé comme optimiseur de référence pour l'ensemble des approches développées dans la suite de ce travail.

Cette première méthode a permis de valider la faisabilité d'une génération directe fondée sur les métriques étudiées et de confirmer l'intérêt des approches d'optimisation par gradient pour la construction d'échantillons de nuages de points. Elle a toutefois mis en évidence plusieurs limitations importantes. Tout d'abord, les résultats obtenus se sont révélés fortement dépendants du choix du nuage de points initial. Des exécutions réalisées dans des conditions identiques mais avec des points de départ différents conduisaient à des échantillons finaux sensiblement distincts, suggérant l'existence de nombreux optima locaux. Cette sensibilité rend difficile la reproductibilité des résultats et limite la robustesse de la méthode. Par ailleurs, le caractère séquentiel de cette construction constitue une limite plus fondamentale. En effet, l'approche repose implicitement sur l'hypothèse qu'un échantillon optimal de taille n peut être obtenu à partir d'un échantillon optimal de taille $n - 1$ auquel on ajoute un nouveau nuage. Une telle propriété n'est cependant pas garantie. L'ajout d'un élément peut modifier l'organisation optimale de l'ensemble de l'échantillon et nécessiter une réorganisation globale des nuages déjà sélectionnés. La qualité finale de la solution dépend ainsi fortement des choix effectués lors des premières étapes de construction. À ces considérations méthodologiques, s'ajoute un coût computationnel élevé. Chaque ajout de nuage nécessite la résolution de plusieurs problèmes d'optimisation dont la complexité augmente à mesure que l'échantillon grandit. Malgré l'efficacité apportée par la différentiation automatique et l'utilisation d'*AdamW*, cette croissance du temps de calcul limite rapidement l'applicabilité de la méthode à des échantillons de grande taille.

Afin de pallier partiellement ces difficultés, une seconde approche hybride a été étudiée. Celle-ci consiste à générer dans un premier temps un échantillon initial par LHS, puis à améliorer itérativement les configurations les plus défavorables au regard du critère *maximin* en

appliquant la même fonction objectif que pour la méthode précédente. L'objectif était de combiner la rapidité de génération du LHS avec la capacité des méthodes d'optimisation à améliorer localement la répartition des nuages. Cette stratégie a effectivement permis d'obtenir des améliorations par rapport à l'échantillon initial tout en réduisant le coût associé à une reconstruction complète de l'échantillon. Néanmoins, les expérimentations ont montré que seules certaines configurations étaient effectivement modifiées au cours du processus. Une part importante de la structure initiale héritée du LHS demeurait donc inchangée, ce qui limitait la capacité de la méthode à explorer réellement l'espace des solutions. De plus, la dépendance à l'initialisation restait présente et aucune garantie ne pouvait être apportée quant à l'obtention d'un optimum global.

Ces deux approches ont ainsi constitué des étapes importantes dans l'élaboration de la méthodologie finale. Elles ont permis de confirmer l'intérêt du critère *maximin*, de valider la pertinence de l'optimisation par gradient dans le cadre étudié et de justifier le choix d'*AdamW* comme optimiseur utilisé tout au long de ce travail. Elles ont également mis en évidence plusieurs difficultés majeures : dépendance aux conditions initiales, risque de convergence vers des optima locaux, absence de garantie sur la qualité globale des solutions obtenues, coût computationnel important et difficulté à optimiser globalement l'ensemble des nuages de points lorsqu'une construction séquentielle est employée. Ces constats ont motivé le développement des approches présentées dans la suite de ce mémoire, tandis que les développements détaillés relatifs à ces méthodes préliminaires sont reportés en annexe.

3.3 Méthodes d'échantillonnage multi-nuages

Bien que la méthode itérative précédente permette de générer des échantillons de nuages de points satisfaisants, elle ne permet pas de garantir l'obtention d'une solution optimale. En effet, les choix effectués lors de l'initialisation influencent directement les étapes suivantes. Ainsi, le nuage ou l'ensemble de nuages utilisé pour initialiser l'échantillon peut modifier la solution finale obtenue par l'algorithme.

Cette dépendance aux décisions prises au cours de la construction de l'échantillon constitue une limite importante de l'approche itérative. Afin de réduire cet effet, nous avons choisi d'adopter une stratégie différente consistant à optimiser simultanément l'ensemble des nuages de points. L'idée est alors d'appliquer directement l'algorithme d'optimisation à tous les nuages de l'échantillon, de manière à permettre une adaptation conjointe de leurs positions au cours de l'optimisation.

3.3.1 Gestion du cardinal des nuages

Bien que l'idée d'optimiser simultanément un grand nombre de nuages de points soit particulièrement séduisante, elle soulève une difficulté majeure liée à la gestion du cardinal de chaque nuage au cours de l'optimisation. En effet, une première approche naïve consisterait à traiter ce problème comme dans la méthode itérative précédente en lançant une optimisation indépendante pour chacun des cardinaux admissibles. Cependant, dès que plusieurs nuages doivent être optimisés simultanément, cette stratégie devient rapidement irréaliste. Il faudrait en effet considérer toutes les combinaisons possibles de nombre de points dans les différents nuages, ce qui conduit à un problème combinatoire dont la complexité augmente très rapidement. Cette

explosion du nombre de cas à étudier apparaît avant même de prendre en compte le coût propre à l'algorithme d'optimisation.

Pour contourner cette difficulté, nous avons choisi d'associer un poids à chacun des points composant nos nuages. Ainsi nous notons w_i le poids associé au points i d'un nuage de points, $W_j = (w_1, \dots, w_n)$ le vecteur de poids associé au nuage de points j et $\mathcal{W} = (W_1, \dots, W_N)$ le vecteur contenant chaque vecteurs de poids associé au nuage de l'échantillon j du nuage de points i . On pourra aussi noter $w_{i,j}$ le poid . Nous pouvons alors effectuer l'optimisation en considérant systématiquement le nombre maximal de points autorisé, en résolvant le problème suivant :

$$E^* = \arg \max_{\substack{E \subset A \\ \#E=N}} \min_{\substack{i \neq j \\ X_i, X_j \in E}} D(W_i, X_i, W_j, X_j).$$

Avec

- E l'échantillon de nuage de points
- $(D(W_i, X_i, W_j, X_j))$ une distance pondérée entre les nuages de points X_i et X_j
- W_i le vecteur de poids associé au nuage de points X_i

Le rôle des poids est ensuite de déterminer quels points sont réellement actifs, un point dont le poids devient inactif étant alors considéré comme absent du nuage. Cette idée reste néanmoins soumise à une contrainte importante. Bien que la distance de Wasserstein et la MMD puissent être calculées sur des nuages pondérés, les poids doivent définir une mesure valide. En particulier, dans le cadre de la MMD, la somme des poids doit être égale à 1. Afin de conserver un cadre de travail commun aux deux métriques, nous avons choisi d'imposer cette même contrainte dans tous les cas et de normaliser les poids de sorte que leur somme soit toujours égale à 1.

Respecter directement cette contrainte au cours d'une descente de gradient est cependant peu pratique. Nous avons alors choisi d'optimiser des variables libres appartenant à $\mathbb{R}$ puis de leur appliquer une transformation garantissant automatiquement l'obtention de poids valides. Nous avons tout d'abord utilisé une transformation basée sur la fonction softmax, qui produit naturellement des poids positifs dont la somme vaut 1. Puis, nous nous sommes ensuite intéressés à une approche fondée sur la fonction sigmoïde afin d'analyser l'influence d'une autre paramétrisation des poids sur le comportement de l'algorithme.

3.3.1.1 Approche softmax

La première transformation étudiée repose donc sur une paramétrisation de type *softmax*, dont les détails méthodologiques ainsi que les résultats expérimentaux sont présentés en Annexe 3.

Bien que cette transformation nous permette de respecter toutes nos contraintes d'optimisation, les expérimentations menées ont mis en évidence une limitation importante. En effet, notre objectif ne se limitait pas à l'optimisation de mesures discrètes, mais consistait également à contrôler le cardinal effectif des nuages générés en faisant émerger une distinction nette entre

points actifs et points inactifs. Malgré plusieurs stratégies étudiées pour identifier ces points actifs à partir des poids optimisés, il est apparu difficile de contrôler précisément les cardinaux obtenus ainsi que leur répartition au sein de l'échantillon. Ces observations ont conduit à introduire un terme de régularisation visant à orienter la distribution des cardinaux vers une distribution cible. La quantité considérée s'écrit :

$$pena_{card}(Nbp) = - \sum_{i=N_{min}}^{N_{max}} \left| \frac{N}{N_{max} - N_{min} + 1} - nbp_i \right|,$$

où $Nbp = (nbp_{N_{min}}, \dots, nbp_{N_{max}})$ est un vecteur contenant les nbp_i représentant le nombre de nuages contenant i points.

Cette régularisation n'a pas vocation à être utilisée seule, mais à être intégrée à la fonction objectif. Elle présente l'avantage de rester indépendante de la distribution cible retenue et pourra ainsi être modifiée si la distribution cible devait être changée. L'introduction de ce terme soulève toutefois une difficulté supplémentaire, son évaluation nécessite une estimation différentiable du nombre de points actifs présents dans chaque nuage. Dans cette optique, des mécanismes de comptage différentiable de type *SoftCount* ont été étudiés, que l'on peut définir par :

$$SoftCount(Y, c) = \sum_{i=1}^n e^{-t\|y_i - c\|^2},$$

Avec :

- $Y = (y_1, \dots, y_n)$ désigne l'ensemble des observations considérées
- c est le point de l'espace pour lequel on cherche à estimer la densité locale d'observations
- t règle la largeur du voisinage pris en compte autour de c . Il détermine donc à quelle vitesse la contribution d'une observation décroît lorsque sa distance à c augmente

Bien qu'ils permettent d'approcher une quantité discrète dans un cadre compatible avec l'optimisation par gradient, leur utilisation nécessitait ici plusieurs niveaux d'approximation successifs afin d'estimer la distribution des cardinaux. Cette accumulation d'approximations dégradait progressivement la qualité des estimations obtenues tout en complexifiant le problème d'optimisation. Ainsi, bien que la paramétrisation par softmax fournisse naturellement des poids valides et soit particulièrement adaptée à l'optimisation sur le simplexe, elle s'est révélée peu adaptée au contrôle direct du cardinal des nuages de points. Cette étude a toutefois permis d'introduire plusieurs concepts qui seront réutilisés dans les approches suivantes, notamment le contrôle explicite de la distribution des cardinaux à travers le terme $pena_{card}$ ainsi que l'utilisation de mécanismes de comptage différentiable de type *SoftCount*. Les développements détaillés relatifs à cette approche sont présentés en Annexe 3.

3.3.1.2 Approche sigmoïde

L'utilisation du softmax soulève donc plusieurs difficultés, notamment lorsqu'il s'agit de déterminer quels points doivent être considérés comme actifs ou inactifs à la fin de l'optimisation. Nous avons donc exploré une approche alternative reposant sur l'utilisation de la fonction

sigmoïde, bien plus connue dans les problèmes de sélection de variables¹⁸, que l'on peut définir par :

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

Contrairement au softmax, la sigmoïde ne produit pas directement une distribution de probabilité. Les valeurs obtenues sont comprises entre 0 et 1 et peuvent être interprétées comme la probabilité d'activation de chaque point. Une étape de normalisation est donc nécessaire avant de pouvoir utiliser ces poids dans le calcul de la distance de Wasserstein ou de la MMD. Pour la suite de ce travail, nous appellerons probabilités d'activation correspondant à un poids $p_i = \sigma(w_i)$ et d'activation associée $\rho_i = \frac{p_i}{\sum_j p_j}$ calculer donc en normalisant les probabilités d'activation.

L'étape normalisation nécessaire avec cette méthode constitue paradoxalement un avantage dans notre contexte. En effet, avant normalisation, les valeurs produites par la sigmoïde permettent d'obtenir une approximation continue du nombre de points actifs dans un nuage. Plus précisément, nous avons $\sum_i \sigma(w_i) \approx \sum_i \mathbf{1}_{w_i > 0}$, où $\mathbf{1}_{w_i > 0}$ désigne l'indicatrice de l'événement $w_i > 0$. Le membre de droite correspond exactement au nombre de points actifs tandis que le membre de gauche fournit une approximation différentiable de cette quantité sous la forme de la somme des probabilités d'activation.

Proposition 2: Soit $W = (w_1, \dots, w_n) \in \mathbb{R}^n$ tel qu'il existe $\delta > 0$ vérifiant

$$|w_i| \geq \delta \quad \forall i.$$

Alors

$$\left| \sum_{i=1}^n \mathbf{1}_{w_i > 0} - \sum_{i=1}^n \sigma(w_i) \right| \leq n \frac{1}{1 + e^\delta}.$$

La preuve de cette proposition se trouve en annexe 4.

Cette propriété montre que l'estimation devient d'autant plus précise que les valeurs w_i sont éloignées de zéro. À l'inverse, lorsque de nombreux poids restent proches de zéro, la qualité de l'approximation se dégrade rapidement. Afin de limiter les chances d'avoir une forte concentration de poids au voisinage de zéro, nous avons introduit un coefficient d'amplification G dépendant de l'itération. Celui-ci est utilisé pour éloigner de zéro les entrées de la sigmoïde en faisant $\sigma(Gw_i)$.

Au cours de l'optimisation, la valeur de G augmente progressivement. Les poids sont alors poussés vers les régions où la sigmoïde est proche de 0 ou de 1, ce qui améliore progressivement l'estimation du nombre de points actifs. Nous évitons néanmoins de choisir une valeur trop grande dès le début de l'optimisation afin de préserver la qualité des gradients. En combinant cette paramétrisation par sigmoïde avec la pénalisation introduite précédemment pour contrôler la répartition des cardinaux, nous obtenons la distribution présentée en FIGURE 5, obtenue en

résolvant le problème :

$$E^*, \mathcal{W}^* = \arg \max_{\substack{E \subset A \\ \#E=N \\ \mathcal{W} \in \mathbb{R}^{N \times Nmax}}} \left(\min_{\substack{i \neq j \\ X_i, X_j \in E \\ W_i, W_j \in \mathcal{W}}} (D(W_i, X_i, W_j, X_j)) + \text{pena}_{card}(Nbp) \right).$$

Avec

- $Nbp = (nbp_1, \dots, nbp_m)$ un vecteur représentant le nombre de nuages ayant un certain nombre de points actif
- $nbp_c = \text{SoftCount}\left(\left(\sum_{j=1}^{Nmax} \sigma(Gw_{i,j})\right)_{i=1}^N, c\right)$ pour $c \in \llbracket Nmin, Nmax \rrbracket$ l'estimation du nombre de nuages ayant c points actifs
- D une distance pondérée entre nuages de points

Nous observons alors une répartition des cardinaux beaucoup plus proche de la distribution uniforme recherchée, ce qui confirme l'intérêt de cette approche pour la gestion des poids.




FIGURE 5 – Répartition des cardinaux des nuages obtenu avec la sigmoïde

Il convient toutefois de noter que cette distribution repose toujours sur une estimation continue du cardinal. Par exemple, un nuage peut temporairement être estimé à 14.3 points actifs au cours de l'optimisation. Afin de pouvoir utiliser cette information dans notre pénalisation, nous avons paramétré notre fonction de softcount de sorte qu'un nuage situé à une distance de 0.5 d'un cardinal contribue encore de manière significative à ce cardinal, de l'ordre de 0.4 point dans le nuage.

Cette stratégie permet de prendre en compte les nuages dont le cardinal reste encore incertain. En contrepartie, elle peut conduire à surestimer le nombre total de nuages présents

dans certaines catégories, puisqu'un même nuage peut contribuer simultanément à plusieurs cardinaux voisins. De même, l'estimation du nombre de nuages associés à un cardinal donné peut être temporairement imprécise lorsque de nombreux nuages possèdent un cardinal estimé proche d'une frontière entre deux valeurs entières, d'une distance de l'ordre de 0.4 à 0.6 du cardinal en question. Bien que ce phénomène peut paraître très inquiétant, il apparaît principalement lors des premières itérations, lorsque l'estimation du nombre de points actifs reste encore peu précise. Son influence diminue progressivement au fur et à mesure que le coefficient d'amplification augmente et que le conte du nombre de points par nuage devient de plus en plus précis.

Afin de réduire encore davantage le risque d'avoir des poids proches de zéro, nous avons introduit une pénalisation supplémentaire de la forme :

$$repul(\mathcal{W}) = \sum_{W \in \mathcal{W}} \sum_{w \in W} e^{-w^2}$$

Cette pénalisation agit comme une légère répulsion autour de zéro et encourage les poids à prendre des valeurs nettement positives ou négatives. Elle améliore ainsi la qualité de l'estimation du cardinal des nuages au cours de l'optimisation.

En pratique, l'ensemble de ces modifications permet de réduire l'erreur moyenne d'estimation du cardinal d'environ 6.8 points à seulement 0.09 point, ce qui rend l'approche suffisamment précise pour être utilisée dans la suite de nos expériences. Nous utiliserons donc comme paramètre de régularisation pour la gestion des poids :

$$reg_{poids}(\mathcal{W}) = pena(Nbp) - repul(\mathcal{W})$$

Avec

- $Nbp = (nbp_1, \dots, nbp_m)$ un vecteur représentant le nombre de nuages ayant un certain nombre de points actif
- $nbp_c = \text{SoftCount}\left(\left(\sum_{j=1}^{N_{\max}} \sigma(Gw_{i,j})\right)_{i=1}^N, c\right)$ pour $c \in \llbracket Nmin, Nmax \rrbracket$ l'estimation du nombre de nuages ayant c points actifs

Ainsi, au vu des résultats obtenus, l'utilisation de la sigmoïde apparaît comme un choix plus pertinent que celle du softmax pour notre problème. Sa capacité à fournir une estimation précise du nombre de points actifs, combinée à son bon comportement vis-à-vis des différentes pénalisations introduites, en fait la solution la plus adaptée parmi celles que nous avons étudiées.

3.3.2 Méthode maximin

Bien que nous disposions désormais d'une méthode permettant de gérer le cardinal de chacun des nuages de points, nous n'avons pas encore détaillé la manière dont les nuages eux-mêmes sont générés, ni même analysé les échantillons obtenus.

Comme pour la méthode itérative précédente, nous nous appuyons sur le critère maximin afin de construire notre échantillon. A chaque itération, les proportions d'activation sont calculées à partir des poids, puis les distances entre nuages de points sont évaluées à l'aide de la




FIGURE 6 – Nuage de points généré à l’aide du critère maximin

métrique choisie. Les différentes pénalisations introduites précédemment sont ensuite ajoutées à la fonction objectif. Nous cherchons donc à résoudre le problème :

$$E^*, \mathcal{W}^* = \arg \max_{\substack{E \subset A \\ \#E=N \\ \mathcal{W} \in \mathbb{R}^{N \times Nmax}}} \left(\min_{\substack{i \neq j \\ X_i, X_j \in E \\ W_i, W_j \in \mathcal{W}}} (D(W_i, X_i, W_j, X_j)) + reg_{poids}(\mathcal{W}) \right).$$

Cette procédure permet d’obtenir l’échantillon présenté à la FIGURE 6, issue de l’optimisation de 54 nuages contenant entre 11 et 20 points. Les autres nuages générés sont présentés en Annexe 5, sur la FIGURE 22.

L’analyse des résultats obtenus met en évidence un phénomène déjà observé dans les méthodes précédentes. À l’exception de quelques nuages, la majorité des configurations générées demeure fortement dégénérée. Bien que tous les nuages respectent la contrainte sur le nombre minimal de points, nombre d’entre eux peuvent être décrits comme étant constitués de seulement quelques positions distinctes portant l’essentiel de la masse sous la forme de plusieurs points partageant les mêmes coordonnées. Ce comportement fournit une information intéressante sur la géométrie de l’espace considéré et sur les solutions privilégiées par le critère maximin. Nous observons notamment que des nuages plus dispersés semblent apparaître à mesure que le nombre de nuages échantillonnés augmente. Toutefois, ces résultats restent difficiles à exploiter dans un contexte applicatif.

En effet, dans la plupart des applications d’ingénierie ou de simulation, les nuages de points manipulés ne sont généralement pas constitués de configurations fortement dégénérées ou du moins pas en majorité. Ainsi, bien que notre échantillon soit, au sens du critère maximin, particulièrement dispersé dans l’espace des nuages de points, il demeure peu représentatif des situations rencontrées en pratique. Nous avons donc poursuivi nos recherches afin de développer des méthodes produisant des échantillons restant *space-filling* tout en générant des nuages de

points davantage exploitables en pratique.

Avant d'introduire ces nouvelles approches, une amélioration du comportement numérique de l'algorithme précédent a été mise en œuvre. L'utilisation directe de l'opérateur minimum dans la fonction objectif s'est révélée susceptible de provoquer des instabilités de convergence, particulièrement au cours des premières itérations. Ce phénomène conduisait parfois à la sélection répétée des mêmes nuages de points, limitant ainsi l'efficacité du processus d'optimisation. Pour pallier cette difficulté, le minimum est remplacé de manière transitoire par une approximation différentiable lors des phases initiales de l'algorithme. Cette approximation favorise une mise à jour plus globale de l'ensemble des nuages de points, au lieu de focaliser l'optimisation sur la seule paire de nuages la plus proche. Elle repose sur l'utilisation de la fonction LogSumExp, dont la propriété suivante est exploitée.

Proposition 3: Soit $(x_1, \dots, x_n) \in \mathbb{R}$ alors la fonction LogSumExp peut être définie par :

$$\text{LSE}(x_1, \dots, x_n) = \log\left(\sum_{i=1}^n \exp(x_i)\right)$$

Alors, pour tout $t > 0$, nous avons :

$$\min\{x_1, \dots, x_n\} - \frac{\log(n)}{t} \leq \frac{1}{-t} \text{LSE}(-tx) < \min\{x_1, \dots, x_n\}$$

avec $t > 0$

La preuve se trouve en annexe 6.

Dans un second temps, nous avons choisi d'effectuer l'optimisation de manière alternée entre les poids et les positions des points. L'idée est alors de découper le problème en deux sous-problèmes, chacun étant optimisé successivement tandis que l'autre est maintenu fixe. Cette stratégie s'apparente aux méthodes d'optimisation par blocs, dans lesquelles chaque sous-ensemble de variables est optimisé en maintenant les autres fixes. Ces méthodes sont fréquemment utilisées lorsque la résolution simultanée du problème complet devient trop coûteuse en mémoire ou conduit à une optimisation numériquement difficile. En effet, cette méthode réduit significativement la quantité de mémoire nécessaire à l'optimisation. Il devient alors possible de générer des échantillons contenant un plus grand nombre de nuages ou de points par nuage avant d'atteindre les limites mémoire de la machine utilisée.

Par ailleurs, seule l'évaluation des distances entre nuages de points dépend simultanément des poids et des positions des points. Les gradients associés aux pénalisations sur les poids peuvent modifier l'échelle relative des différentes composantes du problème d'optimisation. De même, les déplacements des points modifient la géométrie sous-jacente du problème vu par les poids. L'optimisation alternée permet ainsi de traiter séparément ces deux mécanismes et réduit les interférences entre leurs mises à jour successives. Cette séparation tend à améliorer la stabilité de l'optimisation dans nos expériences. Ainsi, les deux problèmes d'optimisation que nous résolvons de manière alternée sont alors :

$$E^* = \arg \max_{\substack{E \subset A \\ \#E=N}} \left(\min_{\substack{i \neq j \\ X_i, X_j \in E}} (D(W_i, X_i, W_j, X_j)) \right).$$

$$\mathcal{W}^* = \arg \max_{\mathcal{W} \in \mathbb{R}^{N \times N^{max}}} \left(\min_{\substack{i \neq j \\ W_i, W_j \in \mathcal{W}}} (D(W_i, X_i, W_j, X_j)) + reg_{poids}(\mathcal{W}) \right).$$

Dans chacune des méthode qui vont suivre le probleme d'optimisation pour trouver $\mathcal{W}^*$ sera le même et ne sera donc pas rappeler à chaque fois.

Cette stratégie ne supprime cependant pas les limitations de la méthode de base. Elle ne fait qu'en atténuer certains effets, sans modifier fondamentalement le problème d'optimisation considéré. Néanmoins, elle constitue une amélioration pratique importante en permettant la génération d'échantillons plus grands tout en réduisant les contraintes mémoire. Elle fournit également un cadre naturellement extensible si, à l'avenir, il devient nécessaire de décomposer davantage le problème afin de diminuer encore les ressources requises pour l'optimisation.

3.3.3 Introduction d'un terme de répulsion

La principale limitation des méthodes reposant uniquement sur le critère maximin est l'apparition fréquente de nuages de points partiellement, voire totalement, dégénérés. En effet, l'optimisation tend régulièrement à superposer plusieurs points en une même position lorsque cela permet d'améliorer le critère considéré.

Or, dans de nombreuses applications pratiques, et notamment dans le domaine éolien, pour le placement de celle-ci, une telle situation n'est pas réaliste. Deux points ne peuvent généralement pas occuper exactement la même position dans l'espace. Il apparaît donc naturel d'introduire un mécanisme empêchant la superposition des points au sein d'un même nuage. Dans cette optique, nous avons ajouté à la fonction objectif un terme de répulsion définissant une distance minimale souhaitée entre les points d'un même nuage. Cette pénalisation est donnée par :

$$pena_repul(D) = \sum_{i < j}^n ReLu(\epsilon - D_{i,j})$$

Avec :

$$ReLu(x) = \max(0, x)$$

- ϵ la distance à laquel l'on veut repousser les points les un des autre
- D la matrice des distances entre les points d'un même nuage et donc $D_{i,j}$ la distance entre les points i et j d'un nuage de point

Cette pénalisation est nulle lorsque les points sont suffisamment éloignés les uns des autres et augmente de manière linéaire dès que deux points se rapprochent à une distance inférieure à ϵ . Elle encourage ainsi l'apparition de nuages moins dégénérés tout en conservant l'objectif principal d'échantillonnage *space-filling* en continuant à optimiser le critère de maximin. Ainsi le problème d'optimisation devients alors :

$$E^* = \arg \max_{\substack{E \subset A \\ \#E=N}} \left(\min_{\substack{i \neq j \\ X_i, X_j \in E}} (D(W_i, X_i, W_j, X_j)) - \sum_{i=1}^N pena_repul(D_i) \right).$$

Avec D_i la matrice de distance euclidienne entre les points du nuage i

Les résultats présentés en FIGURE 7 obtenue en générant 54 nuages contenant entre 28 et 35 points (nuages restant en Annexe 7 sur la FIGURE 23), sont déjà nettement plus exploitables que ceux produits par une optimisation fondée uniquement sur le critère maximin. Les solutions dégénérées observées précédemment disparaissent totalement et les points restent désormais répartis sur plusieurs positions distinctes.




FIGURE 7 – Nuage de points généré à l’aide du critère maximin

Cette amélioration s’accompagne cependant d’un nouvel effet indésirable. Bien que les nuages générés ne soient plus dégénérés, ils présentent désormais des structures très similaires les uns aux autres. En effet, bien que les nuages aient des géométries relativement différentes avec différent nombre de composantes connexe et avec des formes différentes, les points semblent s’organiser selon des configurations proches d’un maillage régulier, donnant visuellement l’impression que les nuages ont été construit à partir d’une même grille. Nous remarquons donc que les points au sein d’une même composante connexe se positionne en majorité à la distance minimal que nous permettons de leur voisin le plus proche, ou du moins à une distance proche de celle-ci. La pénalisation introduite résout donc le problème de la dégénérescence, mais tend simultanément à réduire la diversité géométrique des nuages obtenus.

3.3.4 Introduction d’un parametre de répulsion adaptative

L’objectif initial de la pénalisation par répulsion était d’éviter l’apparition de nuages dégénérés. Or, ces derniers constituent malgré tout une partie légitime de l’espace des nuages de points et certaines applications peuvent même favoriser ce type de configurations. Dès lors, le véritable enjeu n’est pas tant d’interdire les nuages dégénérés que d’en limiter l’apparition sans pour autant déformer la géométrie de l’espace considéré. Dans cette optique, une pénalisation a

été élaborée afin de favoriser une plus grande diversité de formes tout en préservant la possibilité d'obtenir des nuages dégénérés lorsque ceux-ci constituent des solutions pertinentes. Plutôt que d'agir directement sur les distances entre les points d'un nuage, l'approche retenue repose sur la distribution induite par les distances minimales observées au sein des nuages de l'échantillon. Pour chaque nuage, la distance minimale entre deux de ses points est calculée. La distribution de ces distances minimales est ensuite considérée à l'échelle de l'ensemble de l'échantillon. Afin d'encourager l'exploration d'un large éventail de configurations géométriques, la distribution cible est choisie comme une loi uniforme sur l'ensemble des valeurs admissibles de cette distance minimale, dont la caractérisation sera précisée ultérieurement.

La première difficulté de cette méthode consiste à calculer correctement la distance minimale dans chaque nuage. En effet, les points associés à un poids négatifs ne doivent pas intervenir dans ce calcul. Dans le cas contraire, une paire de points inactive pourrait être identifiée comme la paire la plus proche et conduire à une estimation fortement biaisée de la distance minimale réelle du nuage. Afin de résoudre ce problème, nous utilisons simplement une indicatrice permettant de sélectionner les points actifs. Bien que cette opération ne soit pas différentiable en fonction des poids et n'intervienne donc pas dans l'optimisation de ceux-ci, elle ne pose pas de difficulté pour l'optimisation des positions des points, qui est le seul objectif de cette pénalisation. Ainsi, nous pouvons facilement obtenir :

$$Dmin_{intra} = (dmin_1, \dots, dmin_N)$$

Avec :

$$dmin_k = \min_{i \neq j} (D(x_i, x_j) \mathbf{1}_{w_i > 0} \mathbf{1}_{w_j > 0})$$

Et :

- D la distance euclidienne entre deux points
- $dmin_k$ la distance minimale entre deux points du nuage de points k

Une fois la distribution des distances minimales obtenue, il reste à la comparer à la distribution uniforme choisie comme référence. Pour cela, nous utilisons une distance quadratique de type Cramér-von Mises⁹ entre les deux distributions, en comparant leurs quantiles respectifs. Cette comparaison nécessite une opération de tri, qui n'est pas partout différentiable. Toutefois, cela ne constitue pas un obstacle dans notre cas. En effet, les implémentations modernes de PyTorch permettent de propager les gradients à travers cette opération dans la plupart des situations. Les seules singularités apparaissent lorsque deux valeurs échangent leur ordre relatif, ce qui reste rare en pratique et n'introduit qu'une légère perturbation locale du gradient, sans remettre en cause la convergence observée de l'algorithme. Ainsi, nous pouvons formaliser cette distance par :

$$CvM_{U(0,bs)}(Dmin_{intra}) = \frac{1}{N} \sum_{i=1}^N (q_{Dmin_{intra}}(\frac{i}{N}) - q_{U(0,bs)}(\frac{i}{N}))^2$$

Avec :

- $q_G(\alpha)$ le quantile d'ordre α de la distribution G

- $U(0, bs)$ la loi uniforme sur l'intervalle $[0, bs]$
- bs la borne supérieure de l'intervalle de nos valeurs précisé dans le paragraphe ci-dessous

Il reste alors à déterminer une valeur de référence raisonnable permettant de normaliser la distance minimale observée. Pour cela, considérons un espace de dimension d et de volume v , dans lequel nous répartissons uniformément N points. Si l'on découpe l'espace en N cellules de même volume, chacune d'entre elles possède un volume égal à $\frac{v}{N}$. Une distance caractéristique associée à une telle cellule est alors donnée par $(\frac{v}{N})^{1/d}$. Cette quantité ne constitue pas la borne supérieure exacte recherchée. Elle fournit néanmoins un ordre de grandeur cohérent pour la borne supérieur de la distance minimale et s'est révélée suffisante dans nos expériences. Nous considérons donc pour le reste de ce rapport $bs = (\frac{v}{N})^{1/d}$. Ainsi, le problème d'optimisation résolu ici s'écrit :

$$E^* = \arg \max_{\substack{E \subset A \\ \#E=N}} \left(\min_{\substack{i \neq j \\ X_i, X_j \in E}} (D(W_i, X_i, W_j, X_j)) - CvM_{U(0,bs)}(Dmin_{intra}). \right)$$

Une fois cette pénalisation mise en place, en générant à nouveau 54 nuages contenant entre 28 et 35 points, nous obtenons les nuages de la FIGURE 8, avec le reste de l'échantillon présent dans l'annexe 8 sur la FIGURE 24. Contrairement aux méthodes précédentes, les nuages générés présentent une diversité géométrique beaucoup plus importante. Nous observons simultanément des nuages fortement concentrés, des nuages très dispersés ainsi que de nombreuses configurations intermédiaires.




FIGURE 8 – Nuage de points générés à l'aide du critère maximin avec paramètre de répulsion adaptative

Bien que cette méthode produise des nuages de points beaucoup plus variés, elle conserve la principale faiblesse des approches précédentes, la forte dépendance à l'initialisation. En effet, la fonction objectif demeurant non convexe, l'utilisation d'une méthode de descente de

gradient conduit fréquemment à la convergence vers des minima locaux. Deux pistes peuvent alors être envisagées. La première consiste à utiliser des méthodes d'optimisation stochastiques. Cependant, celles-ci passent généralement difficilement à l'échelle lorsque la dimension du problème augmente et deviennent rapidement coûteuses dans notre contexte. La seconde consiste à employer une stratégie de type multi-start. Cette approche est plus réaliste dans notre cas puisqu'elle permet d'explorer plusieurs bassins d'attraction tout en conservant notre schéma d'optimisation actuel. Elle ne garantit toutefois pas davantage la convergence vers le minimum global et augmente directement le temps de calcul. Son coût reste néanmoins plus maîtrisé, puisqu'il croît linéairement avec le nombre de redémarrages effectués. Bien que ces pistes soient prometteuses, nous avons choisi de concentrer nos efforts sur l'amélioration des méthodes précédemment présentées ainsi que sur l'étude d'une dernière approche, détaillée dans la section suivante. Ce choix nous a également permis de consacrer davantage de temps à l'évaluation de ces méthodes sur un cas d'étude pratique, qui sera présentés par la suite.

3.3.5 Alternative aux approches maximines

L'un des principaux inconvénients des méthodes présentées jusqu'à présent réside dans le fait qu'elles reposent toutes sur un critère maximin et héritent, par conséquent, des limitations qui lui sont associées. En particulier, les méthodes précédentes ont mis en évidence une concentration accrue des nuages de points à proximité des frontières de l'espace étudié. Ce comportement découle directement de la recherche de la plus grande distance minimale possible entre les éléments de l'échantillon. Afin de s'affranchir de cet effet, une méthode alternative, que nous appellerons méthode JLN, a été développée pour générer des nuages de points conservant des propriétés de remplissage de l'espace (*space-filling*) sans reposer explicitement sur un critère maximin et sans présenter les biais induits par celui-ci. Cette méthode repose sur l'idée que la distribution des distances entre nuages de points suffisamment bien répartis dans leur espace pourrait présenter des caractéristiques proches de celles observées entre des points issus d'un tirage uniforme. Si cette hypothèse s'avère correcte, ou du moins raisonnable, il devient alors possible de construire un échantillonnage en cherchant non plus à maximiser une distance minimale, mais à reproduire une distribution de distances de référence. Ainsi, le problème d'optimisation devient :

$$E^* = \arg \min_{\substack{E \subset A \\ \#E=N}} (D(D_{du}, D_{cl}(E, \mathcal{W}))).$$

$$\mathcal{W}^* = \arg \min_{\mathcal{W} \in \mathbb{R}^{N \times N_{max}}} (D(D_{du}, D_{cl}(E, \mathcal{W}))) + reg_{poids}(\mathcal{W}).$$

Avec :

- D une distance entre distribution
- D_{du} un vecteur contenant toutes les distances entre les points d'un tirage uniforme en dimension d
- $D_{cl}(E, \mathcal{W})$ un vecteur contenant toutes les distances entre les nuages de points

En revanche, cette méthode nécessite de s'interroger sur la dimension dans laquelle nous effectuons notre tirage uniforme. Intuitivement, il semble naturel de choisir la même dimension que celle dans laquelle vivent les nuages de points. Cette hypothèse tend notamment à se justifier par le fait que, dans un hypercube unité, la distance maximale possible entre deux nuages

de points est alors la même que la distance maximale possible entre deux points de cet espace. Nous avons néanmoins souhaité vérifier expérimentalement si cette intuition était effectivement pertinente.

Afin de rendre cette comparaison possible, toutes les distances ont été normalisées de manière à appartenir à l'intervalle $[0, 1]$, indépendamment de la dimension considérée. Comme le montre la FIGURE 9, la distribution des distances obtenue lors d'un tirage uniforme dépend fortement de la dimension de l'espace. Ce phénomène est cohérent avec un résultat classique de la géométrie en grande dimension qui est que lorsque la dimension augmente, les distances entre points tendent progressivement à se concentrer autour d'une valeur quasi constante. Cet effet reste relativement discret pour des dimensions modérées mais devient particulièrement visible lorsque l'on atteint des dimensions élevées, comme la dimension 50 présentée sur la figure.




FIGURE 9 – Comparaison entre les fonctions de répartition des distances points à points dans un tirage uniforme en fonction de la dimension

Cette observation met en évidence une difficulté classique des méthodes fondées sur les distances. Lorsque la dimension devient très grande, le pouvoir discriminant des distances diminue fortement. Néanmoins, tant que la dimension reste raisonnable, cet effet demeure toutefois suffisamment faible pour que les distances conservent un intérêt pratique.

Il est alors possible de définir cette nouvelle méthode d'échantillonnage. À l'instar des approches précédentes, la stratégie employée pour gérer le nombre de points dans chaque nuage demeure inchangée. En revanche, la fonction objectif associée au positionnement des points est profondément modifiée. Plutôt que de construire la fonction de coût à partir d'un critère maximum complété par différentes pénalisations, la fonction objectif est désormais définie comme la distance de Wasserstein entre la distribution des distances observées entre les nuages de points de l'échantillon et la distribution des distances point à point obtenue à partir d'un tirage uniforme d'une dimension restant à déterminer. La minimisation de cette distance de Wasserstein vise ainsi à rapprocher au maximum les fonctions de répartition associées à ces deux

distributions. Le problème d'optimisation peut dès lors être formulé de la manière suivante :

$$E^* = \arg \min_{\substack{E \subset A \\ \#E=N}} (W(D_{du}, D_{cl}(E, \mathcal{W}))).$$

- W La distance de Wasserstein entre nos deux distributions
- D_{du} un vecteur contenant toutes les distances entre les points d'un tirage uniforme en dimension d
- $D_{cl}(E, \mathcal{W})$ un vecteur contenant toutes les distances entre les nuages de points

Vient alors le problème du choix de la dimension dans laquelle est effectué le tirage uniforme. Pour cela, nous générons des nuages de points en dimension 2 dans le carré unité avec différents tirages uniformes de référence, puis pour chaque échantillon de nuage nous superposons chacun de nos nuages afin de pouvoir repérer toute anomalie potentielle dans leur couverture de l'espace.




FIGURE 10 – Comparaison des résultats obtenus avec la génération itérative en utilisant la MMD, la distance de Wasserstein et une troisième métrique.

Ainsi, les résultats obtenus en FIGURE 10 montrent rapidement qu'un tirage uniforme de référence en dimension 1 n'est pas adapté. Les nuages générés, une fois tous projeté dans un même espace, ont tendance à se concentrer dans une région particulière, sur la figure dans le coin en bas à droite. Nous avons également observé que la localisation de cette concentration dépend fortement de l'initialisation choisie et étants presque toujours dans l'un des coins de l'espace. Ce comportement s'explique vraisemblablement par la proportion plus importante de petites distances présente dans une distribution uniforme de dimension 1 par rapport aux dimensions supérieures, ce qui tend à favoriser l'apparition d'une zone avec une forte densité de nuage. À l'inverse, lorsque le tirage uniforme de référence est réalisé en dimension 3, nous observons une légère concentration des nuages à proximité des frontières de l'espace. Cette observation tend à confirmer notre intuition initiale selon laquelle utiliser une dimension supérieure favorise progressivement les régions proches des bords. Ces résultats semblent donc confirmer, dans le cas des nuages de points en dimension 2, l'intérêt d'utiliser un tirage uniforme de référence dans cette même dimension. Nous adopterons donc cette hypothèse pour l'ensemble des expériences présentées dans la suite de ce travail. La question de l'influence de la dimension de référence lorsque la dimension du problème augmente sera toutefois brièvement rediscutée en conclusion.

Après avoir étudié la répartition globale des nuages de points, il convient également d'examiner leur géométrie interne. Comme le montre la FIGURE 11, obtenue en générant 54 nuages contenant entre 28 et 34 points et dont les nuages restant sont sur la FIGURE 25 en Annexe 9, les nuages générés par cette méthode présentent une structure beaucoup moins rigide que ceux obtenus à l'aide des approches précédentes. Les distances entre points sont plus variées et les configurations observées paraissent visuellement plus organiques. En contrepartie, les nuages générés semblent majoritairement constitués d'une unique composante connexe, ce qui n'était pas nécessairement le cas des méthodes fondées sur le critère maximin. Cette nouvelle approche semble ainsi privilégier des structures globalement cohérentes plutôt qu'un ensemble de sous-groupes distincts.




FIGURE 11 – Nuage de points généré à l'aide de la méthode JLN

Dès lors, dans un contexte comme le placement d'éoliennes où une certaine structuration spatiale est recherchée, les méthodes précédentes peuvent rester plus pertinentes. En revanche, pour des applications où une organisation globale plus naturelle est souhaitée, cette approche présente des caractéristiques particulièrement intéressantes. Enfin, bien que cette méthode paraisse prometteuse, elle présente encore plusieurs limitations. Par exemple, comme les méthodes précédentes, elle reste sensible à l'initialisation.

4 Évaluation des méthodes proposées

Les différentes méthodes d'échantillonnage étudiées présentent des comportements qui semblent différer significativement. Toutefois, les conclusions tirées jusqu'à présent reposent principalement sur une analyse visuelle des résultats. Une évaluation quantitative apparaît donc nécessaire afin de comparer de manière rigoureuse les performances respectives de ces approches. Malheureusement, cette comparaison se heurte à plusieurs difficultés. Tout d'abord, les critères fondés sur le maximin ou sur les distances aux plus proches voisins ne sont pas adaptés

à notre problème. En effet, nombres des méthodes présentées précédemment ont précisément été construites autour de ces critères. Les utiliser comme outil d'évaluation conduirait donc à favoriser artificiellement ces mêmes méthodes. Les approches fondées sur la discrédance ne sont pas davantage envisageables. Leur utilisation nécessite en effet la connaissance d'une mesure uniforme de référence sur l'espace considéré. Or, toute la difficulté de notre problème réside dans le fait que cette mesure uniforme n'est pas connue sur l'espace des nuages de points à cardinal variable. Enfin, les méthodes consistant à partitionner l'espace puis à étudier la densité des échantillons dans chacune des régions obtenues soulèvent également plusieurs difficultés. Les nuages de points générés ne vivent pas tous dans des espaces de même dimension, du a leur nombre de points variable. La définition d'un découpage cohérent de l'espace ainsi que l'interprétation des densités obtenues deviennent alors particulièrement délicates. Face à ces limitations, il ne reste que peu de possibilités pour comparer directement nos différentes méthodes.

4.1 Application au cas AMON

Dans un premier temps, ne disposant pas de critère général permettant de comparer rigoureusement l'ensemble de nos méthodes d'échantillonnage, nous avons choisi de les évaluer sur un cas pratique. Pour cela, nous nous sommes appuyés sur les travaux de Joséphine Gobert⁷ réalisés à partir du package `PyWake`. Ceux-ci permettent d'estimer la production énergétique d'un parc éolien (eap) représenté par un nuage de points. Le code utilisé a été légèrement modifié afin de privilégier la rapidité de calcul au détriment d'une partie de la précision. La version employée au cours de nos expériences, ainsi que le terrain et la rose des vents considérés, sont disponibles sur le dépôt GitHub associé⁵.

L'objectif de cette étude n'est pas de déterminer quelle méthode génère les meilleurs parcs éoliens, mais plutôt de comparer leur capacité à explorer l'espace des solutions. Pour cela, nous nous intéressons à la répartition des valeurs de production obtenues. Une méthode sera ici considérée comme intéressante si elle est capable de générer des nuages de points conduisant à une grande diversité de productions énergétiques. Nous avons ainsi généré 100 nuages de points contenant chacun entre 22 et 30 points à l'aide des différentes méthodes d'échantillonnage simultané.

Les résultats obtenus sont présentés FIGURE 12. Nous observons que les méthodes fondées sur la répulsion adaptative ainsi que la méthode JLN produisent les répartitions les plus étendus sur les valeurs de sortie. Elles semblent donc explorer plus efficacement les différentes zones de l'espace des solutions associées à ce problème. D'autant que la borne maximal que nous pouvons obtenir avec Amon semble nous donner une valeur du même ordre que la valeur maximale que nous trouve la méthode basée sur une répulsion adaptative.

Pour ce qui est du pic observé en 0 pour la méthode maximin sans pénalisation n'est pas surprenant. En effet, le code utilisé renvoie par défaut une valeur nulle lorsque deux éoliennes occupent exactement la même position. Or, comme nous l'avons vu précédemment, cette méthode génère fréquemment des nuages dégénérés contenant des points superposés. Le fait que certaines valeurs demeurent néanmoins strictement positives s'explique par les approximations




FIGURE 12 – Fonction de répartition des eap générés par nos nuages de points, pour les méthodes d'échantillonnage

numériques de l'algorithme. Bien que plusieurs points apparaissent visuellement confondus et devraient théoriquement l'être, les imprécisions de calcul ainsi que l'arrêt de l'optimisation avant convergence parfaite peuvent laisser subsister une faible distance entre eux. Dans ce cas, le modèle considère les éoliennes comme distinctes et calcule une production énergétique associée, même si une telle configuration ne serait pas exploitable en pratique. À l'inverse, le comportement observé pour la méthode maximin associée à un terme de répulsion était également attendu. Les nuages générés présentent des géométries très similaires, ce qui conduit naturellement à des productions énergétiques relativement proches les unes des autres. La faible diversité géométrique observée dans les échantillons se retrouve donc directement dans la distribution des valeurs produites par le modèle.

Enfin, il est rassurant de constater que, à l'exception de la méthode maximin avec répulsion, et dans une moindre mesure de la méthode maximin sans pénalisation, les différentes approches étudiées produisent une répartition des sorties plus large que celle obtenue à l'aide d'un simple tirage aléatoire. Bien que cette observation soit limitée au cas particulier étudié ici, elle suggère que les méthodes développées sont capables d'explorer l'espace des solutions de manière plus efficace qu'un échantillonnage naïf dans le cadre de ce problème de production énergétique éolienne.

4.2 Analyse par diagrammes de persistance

Comme nous l'avons mentionné précédemment, une grande partie des outils habituellement utilisés pour comparer des méthodes d'échantillonnage ne sont pas directement applicables à notre problème. Nous avons donc choisi, dans un second temps, de nous tourner vers l'analyse topologique des données au travers des diagrammes de persistance.

Définition 13 (diagramme de persistance) :^{11;10} Le diagramme de persistance est un outil permettant de visualiser la durée de vie des caractéristiques topologiques d'un jeu de données. Chaque point du diagramme est associé à une caractéristique topologique à travers sa valeur de naissance et sa valeur de disparition. Dans notre étude, nous nous intéresserons principalement aux homologies β_0 et β_1 . L'homologie β_0 décrit l'apparition et la fusion des composantes connexes, tandis que l'homologie β_1 décrit l'apparition et la disparition des cycles (courbes fermées) présents dans les nuages de points. Les caractéristiques les plus persistantes sont généralement considérées comme les plus significatives.

L'idée sous-jacente est qu'une grande diversité dans les diagrammes de persistance associés aux nuages de points d'un échantillon devrait refléter une plus grande diversité topologique au sein de cet échantillon. Afin de comparer nos différentes méthodes d'échantillonnage, il est donc nécessaire de disposer d'un moyen de comparer ces diagrammes entre eux. Or, une homologie persistante peut être représentée comme un nuage de points dans le plan naissance-mort. Il devient donc naturel d'utiliser une distance de Wasserstein entre diagrammes de persistance. En calculant les distances deux à deux entre les diagrammes associés aux différents nuages de points d'un échantillon, nous obtenons une distribution de distances topologiques. Une méthode produisant des diagrammes très variés devrait alors présenter des distances moyennes plus importantes. Les résultats obtenus selon cette procédure sont présentés à les FIGURES 13 et 14. Parmi les méthodes évaluées, l'approche reposant sur le critère maximin couplé à une répulsion adaptative présente les distances moyennes les plus élevées, tant pour l'homologie β_0 que pour l'homologie β_1 . Ces résultats indiquent que cette méthode produit les nuages de points les plus diversifiés du point de vue topologique parmi les approches considérées.




FIGURE 13 – Comparaison entre les distributions des distances entre les homologie β_0 des différentes méthodes

Pour les homologies β_0 aucune de nos méthodes à l'exception de celle reposant sur le para-

mètre de répulsion adaptative ne sort particulièrement du lot, ce qui tend à montrer que seule cette méthode nous permet de générer des nuages de points contenant une certaine diversité parmi leur composante connexe. Et pour ce qui est de l'homologie β_1 , comme nous l'avons dit précédemment la méthode qui sort le plus du lot est encore celle basée sur une répulsion adaptative. Mais dans ce cas-là son avantage est nettement moins significatif que pour β_0 . Pour ce qui est de nos autres méthodes, elles sont toutes moins efficaces qu'un tirage de nuage aléatoire, effectuer en tirant uniformément sur notre espace. En revanche, il semble se dégager, comme nous pouvions nous y attendre, que la méthode basée uniquement sur le maximin semble être celle étant la moins performante sur ce critère. Pour ce qui est des méthodes avec paramètre de répulsion et celle basée sur la méthode JLN, elle présente une performance relativement similaire et relativement proche de celle obtenue avec un tirage aléatoire.




FIGURE 14 – Comparaison entre les distributions des distances entre les homologie β_1 des différentes méthodes

Bien que ces résultats paraissent favoriser assez nettement la méthode fondée sur la répulsion adaptative, ils demeurent insuffisants pour conclure à eux seuls. En effet, les diagrammes de persistance ne mesurent que la diversité topologique des nuages générés. Ils ne fournissent aucune information sur la manière dont ces nuages sont répartis dans l'espace exploré. Un échantillon composé de nuages topologiquement très différents mais concentré dans une même région de l'espace pourrait ainsi obtenir d'excellents résultats selon ce critère. À l'inverse, un échantillon formé de nuages relativement similaires mais réparti dans des zones très éloignées de l'espace pourrait être pénalisé. Il apparaît donc difficile de tirer des conclusions définitives à partir de cette seule analyse. Ainsi, bien que les résultats obtenus semblent favoriser certaines méthodes, ils restent insuffisants pour établir un classement robuste de l'ensemble des approches étudiées.

5 Étude comparative de l'utilisation des distances MMD et Wasserstein

Depuis le début de ce rapport, nous ne précisons pas directement la distance utilisée lors de la construction de chacune de nos méthodes. Et pour cause jusqu'ici, n'ayant pas d'autres méthodes de comparaison que la comparaison visuelle, nous n'avions concrètement pas de moyenne de comparaison réellement fiable pour pouvoir comparer nos méthodes. Nous remarquons pour chacune d'entre elle que nos résultats finaux étaient certes différents, mais conservais toujours la même forme, et ce, quelle que soit la distance utilisée. Nous pouvons notamment le voir sur les FIGURE de 27 à 34 de l'annexe 10, qui nous montre pour une même initialisation, les nuages que nous obtenons avec l'une ou l'autre des distances prise en référence. Ces figures sont ainsi obtenues en générant 36 nuages de points contenant chacun entre 25 et 34 points.




FIGURE 15 – Comparaison entre les distributions des distances entre les homologie β_1 des différentes méthodes

Les conclusions que nous obtenons étant identiques sur chacune des méthodes que nous avons exploré au cours de ce stage, seul la méthode utilisant une répulsion adaptative sera analysée dans cette partie. Pour comparer les résultats obtenus avec ces deux distances, nous avons dans un premier temps regardé les diagrammes de persistance que nous obtenions avec chacune de celles-ci. Mais comme nous pouvons le voir sur la FIGURE 15, nous ne constatons pas de distance meilleure qu'une autre. Ceci tend à se confirmer encore un peu plus lorsque l'on prend une distance indépendante de MMD et de Wasserstein et que l'on calcule la distance minimale entre deux nuages de points de cet ensemble. En prenant la distance de Chamfer, que l'on peut définir par

$$d_C(X, Y) = \frac{1}{|X|} \sum_{x \in X} \min_{y \in Y} \|x - y\|^2 + \frac{1}{|Y|} \sum_{y \in Y} \min_{x \in X} \|x - y\|^2,$$

où X et Y désignent deux nuages de points. Nous remarquons sur la FIGURE 16 que ni l'un ni l'autre des distances semble prendre un quelconque avantage significatif.




FIGURE 16 – Comparaison des distances minimal

Bien que ces résultats ne soient pas suffisants pour affirmer que ces deux distances nous donnent des résultats équivalents en qualité, nous n'avons pour l'instant, tout comme pour la comparaison de nos différentes méthodes, pas de meilleur méthode pour comparer les résultats obtenus avec nos deux distances. Ainsi, à ce stade, nous considérons toujours ces deux distances comme équivalente pour la génération de nos échantillons, faute de meilleur moyen de comparaison.

6 Conclusion et perspectives

L'objectif de ce stage était de développer des méthodes d'échantillonnage *space-filling* de l'ensemble des nuages de points. Dans ce cadre, plusieurs approches ont été étudiées et implémentées afin d'évaluer leur capacité à maximiser la diversité des nuages sélectionnés. Les travaux réalisés au cours de ce stage nous ont conduits à explorer deux grandes familles de méthodes d'échantillonnage. La première est fondée sur le critère du maximin et a donné naissance à plusieurs variantes. Nous avons notamment étudié une version sans pénalisation, une version intégrant un paramètre de répulsion fixe entre les points d'un même nuage ainsi qu'une version reposant sur un mécanisme de répulsion adaptatif. La seconde famille, désignée dans ce rapport sous le nom de méthode JLN, repose quant à elle sur la comparaison entre la distribution des distances observées dans les nuages de points et de celle obtenue à partir d'un tirage uniforme de référence.

Les différentes expérimentations réalisées au cours du stage ont permis de faire émerger deux approches particulièrement prometteuses, à savoir la méthode JLN et la méthode maximin avec répulsion adaptative. Les résultats obtenus jusqu'à présent tendent à montrer que cette dernière offre globalement les performances les plus intéressantes parmi les méthodes étudiées. Il convient toutefois de rester prudent dans l'interprétation de ces résultats. En effet, les comparaisons réalisées jusqu'à présent ne prennent en compte qu'une partie des caractéristiques qui font d'un échantillon de nuage de point un échantillon *space-filling* et ne permettent donc pas

d'établir avec certitude la supériorité d'une méthode sur l'autre. Il serait nécessaire d'effectuer d'autres tests afin de confirmer les tendances observées au cours de ce travail.

Au-delà de la problématique principale étudiée dans ce mémoire, un travail exploratoire a également été mené afin d'étudier la possibilité de réaliser un échantillonnage visant non plus à couvrir de manière homogène l'espace des nuages de points, mais l'espace des sorties d'une fonction d'intérêt. L'objectif était alors de sélectionner des nuages de points permettant d'obtenir une exploration la plus diversifiée possible des réponses produites par cette fonction, même si les nuages retenus ne constituent pas nécessairement un échantillon *space-filling* de l'espace d'entrée. Les premiers résultats obtenus sur plusieurs cas de test simples montrent que cette approche semble réalisable et qu'il est effectivement possible de construire des ensembles de nuages favorisant une couverture plus homogène de l'espace des sorties. Cependant, les développements réalisés dans ce cadre restent encore préliminaires et nécessiteraient des travaux supplémentaires, tant sur le plan méthodologique que sur celui de la validation expérimentale, afin d'aboutir à des résultats suffisamment robustes pour être exploités dans un contexte applicatif. Malgré cela, cette étude exploratoire a mis en évidence une piste de recherche particulièrement intéressante, susceptible d'étendre les applications des méthodes développées au cours du stage.

Bien que les résultats présentés dans ce rapport se concentrent principalement sur la génération de nuages de points en dimension 2, l'ensemble des méthodes développées a également été généralisé à des espaces de dimension supérieure. Les expérimentations menées montrent que les comportements observés pour les approches fondées sur le critère maximin se retrouvent de manière cohérente lorsque la dimension de l'espace augmente. Concernant la méthode JLN, la question du choix de la dimension du tirage de référence se pose également dans le cas multidimensionnel. Si cette problématique mérite une étude plus approfondie, les premiers résultats obtenus suggèrent que le choix consistant à conserver un tirage de référence de même dimension que l'espace considéré constitue une option pertinente. Cette approche a donc été retenue pour les expérimentations réalisées. Ces travaux complémentaires n'ont pas été détaillés dans ce rapport afin de privilégier la présentation des principaux développements et résultats. L'ensemble des implémentations correspondantes est néanmoins disponible sur le dépôt GitHub associé au projet⁴.

À la date de rédaction de ce mémoire, les travaux réalisés ont permis d'identifier plusieurs pistes méthodologiques pertinentes pour répondre à la problématique étudiée. Ils ont également mis en évidence un certain nombre de limites et de questions ouvertes qui mériteraient d'être approfondies. La fin du stage sera notamment consacrée à une étude plus détaillée des méthodes ayant donné les résultats les plus prometteurs, afin de mieux comprendre leurs comportements respectifs, leurs limites et les contextes dans lesquels elles sont les plus adaptées. Une attention particulière sera également portée à l'amélioration des protocoles d'évaluation. Les comparaisons réalisées jusqu'à présent ont permis de dégager plusieurs tendances intéressantes, mais celles-ci reposent encore sur un nombre limité de configurations. L'étude de nouveaux cas d'application et la mise en place d'indicateurs complémentaires devraient permettre de renforcer la portée des conclusions obtenues. Par ailleurs, plusieurs développements importants restent à réaliser concernant l'adaptation des méthodes proposées à des espaces non connexes et/ou non convexes. Les principes utilisés tout au long de ce travail ne semblent pas, à première vue, empê-

cher une telle généralisation. En revanche, les implémentations actuelles ont principalement été conçues pour des espaces relativement simples et nécessitent encore plusieurs évolutions afin de pouvoir traiter efficacement des géométries plus complexes. Cette question constitue une étape importante pour envisager une utilisation des méthodes développées dans des contextes applicatifs plus réalistes.

Ainsi, ce stage a permis de poser les bases d'une méthodologie dédiée à l'échantillonnage *space-filling* de nuages de points à cardinal variable. Plusieurs approches ont pu être proposées, étudiées et comparées, mettant en évidence des comportements sensiblement différents selon les propriétés recherchées. Bien que de nombreuses questions demeurent ouvertes, les résultats obtenus montrent que ce problème peut être abordé suivant plusieurs stratégies complémentaires et fournissent une base solide pour la poursuite des travaux au cours des dernières semaines du stage.

Références

- [1] Mona ABTINI. *Plans prédictifs à taille fixe et séquentiels pour le krigage*. PhD thesis, Ecole centrale de Lyon, 30/08/2018.
- [2] Reza Asad, Reza Babanezhad, Issam Laradji, Nicolas Le Roux, and Sharan Vaswani. Fast convergence of softmax policy mirror ascent. *arXiv preprint arXiv :2411.12042*, 2024. doi : 10.48550/arXiv.2411.12042. URL <https://arxiv.org/abs/2411.12042>.
- [3] Marco Cuturi. Sinkhorn distances : Lightspeed computation of optimal transport. In C. J. C. Burges, L. Bottou, M. Welling, Z. Ghahramani, and K. Q. Weinberger, editors, *Advances in Neural Information Processing Systems 26 (NIPS 2013)*, pages 2292–2300. Curran Associates, Inc., 2013.
- [4] Loick Diener. Sampling_point_cloud. https://github.com/Loickdiener/Sampling_point_cloud, 2026. Dépôt GitHub, consulté pour la dernière fois le 27 août 2026.
- [5] Loick Diener. AMON_modifier. https://github.com/Loickdiener/AMON_modifier, 2026. Version adaptée du projet AMON de Joséphine Gobert⁷ développée dans le cadre de ce travail. Dépôt GitHub, consulté pour la dernière fois le 26 août 2026.
- [6] Sushant S. Garud, Iftekhar A. Karimi, and Markus Kraft. Design of computer experiments : A review. *Computers & Chemical Engineering*, 106 :71–95, 2017. doi : 10.1016/j.compchemeng.2017.05.010.
- [7] Joséphine Gobert. AMON. <https://github.com/josephinegobert/AMON>, 2024. Dépôt GitHub, consulté pour la dernière fois le 12 août 2026.
- [8] V. Roshan Joseph. Space-filling designs for computer experiments : A review. *Quality Engineering*, 28(1) :28–35, 2016. doi : 10.1080/08982112.2015.1100447.
- [9] Le Maki Statheux. Le test de cramér-von mises. <https://lemakistatheux.wordpress.com/2013/08/04/test-de-cramer-von-mises/>, 2013. Article de blog, consulté le 26 août 2026.
- [10] Philippe Malbos. Raconte-moi... la persistance topologique. *Quadrature*, 169 :44–50, 2021. URL <https://hal.science/hal-03345898v1/file/persistanceTopologique.pdf>.
- [11] R. Mosquera. Quelques exemples d’application de l’homologie persistante en mécanique. Présentation au GDR GDM, IRCAM Paris, May 2024. URL <https://gdr-gdm.univ-lr.fr/ircam-2024/files/Mosquera.pdf>. En collaboration avec D. Razafindralandy et A. Hamdouni, La Rochelle Université, présenté le 7 mai 2024.
- [12] Krikamol Muandet, Kenji Fukumizu, Bharath Sriperumbudur, and Bernhard Schölkopf. Kernel mean embedding of distributions : A review and beyond, 2020. URL <https://arxiv.org/abs/1605.09522>. arXiv :1605.09522v4, December 2020.
- [13] Gabriel Peyré and Marco Cuturi. Computational optimal transport. *Foundations and Trends in Machine Learning*, 11(5-6) :355–607, 2019.

- [14] Luc Pronzato. Minimax and maximin space-filling designs : some properties and methods for construction. *Journal de la Société Française de Statistique*, 158(1) :7–36, 2017.
- [15] Luc Pronzato and Werner G. Müller. Design of computer experiments : Space filling and beyond. *Statistics and Computing*, 22(3) :681–701, 2012. doi : 10.1007/s11222-011-9242-3.
- [16] PyTorch Contributors. torch.optim.adamw. <https://docs.pytorch.org/docs/2.13/generated/torch.optim.AdamW.html#torch.optim.AdamW>, 2026. Documentation PyTorch, consultée le 27 août 2026.
- [17] Babacar Sow. *Optimizing and metamodeling functions defined over clouds of points*. PhD thesis, Mines Saint-Etienne, 20/11/2024.
- [18] Yutaro Yamada, Ofir Lindenbaum, Sahand Negahban, and Yuval Kluger. Feature selection using stochastic gates. *arXiv preprint arXiv :1810.04247*, 2018. doi : 10.48550/arXiv.1810.04247. URL <https://arxiv.org/abs/1810.04247>.
- [19] Delbert Yip. Math 612 : Single cell analysis – lecture 13 : Sinkhorn’s algorithm for entropic optimal transport, October 2019. Lecture notes, October 17, 2019. Scribed by Delbert Yip.

Annexe 1




FIGURE 17 – Nuages de points utiliser pour la comparaisons des distance MMD et Wasserstein

Annexe 2 : Approches itérative

Le critère LHS pour la création d'échantillons *space-filling* ayant montré ses limites dans notre contexte, nous avons décidé de nous pencher sur le critère du maximin présenté précédemment. Nous avons donc cherché à maximiser la distance minimale entre les différents nuages de points que nous avons générés, en nous intéressant uniquement sur les composant de nos nuages et non plus sur les paramètres d'une loi.

Génération nuage par nuage

Dans un premier temps, nous avons décidé de résoudre ce problème de manière naïve en générant des nuages les uns après les autres. A chaque itération, nous ajoutons le nuage maximisant sa distance minimale aux nuages déjà présents. Pour trouver ce nuage, à chaque itération, en utilisant un algorithme d'optimisation, nous cherchons, pour tout nombre de points possible, le nuage maximisant sa distance minimale aux autres nuages. Puis nous ne gardons que le nuage parmi tous les nuages générés qui a la plus grande distance minimale au reste de l'échantillon pour l'ajouter à celui-ci.

L'algorithme d'optimisation retenu est AdamW (Adaptive Moment Estimation with Weight Decay). AdamW est une méthode de descente de gradient adaptative qui ajuste automatiquement le taux d'apprentissage de chaque paramètre à partir d'estimations de la moyenne et de la variance des gradients observés au cours de l'entraînement. Cette approche permet généralement d'améliorer la stabilité et la vitesse de convergence par rapport à une descente de gradient classique. Cet algorithme peut être grossièrement écrit comme suit :

Algorithm 1 Version simplifiée d'AdamW adaptée de la documentation PyTorch¹⁶

```

1: Initialisation  $\theta$ ,  $m_0 = 0$ ,  $v_0 = 0$ 
2: for chaque itération  $t$  do
3:    $g_t \leftarrow \nabla_{\theta} \mathcal{L}(\theta_{t-1})$  ▷ Calcul du gradient
4:    $m_t \leftarrow \beta_1 m_{t-1} + (1 - \beta_1) g_t$  ▷ Moyenne des gradients
5:    $v_t \leftarrow \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$  ▷ Variance des gradients
6:    $\hat{m}_t \leftarrow \frac{m_t}{1 - \beta_1^t}$ ,  $\hat{v}_t \leftarrow \frac{v_t}{1 - \beta_2^t}$  ▷ Correction du biais
7:    $\theta_t \leftarrow \theta_{t-1} - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon} - \eta \lambda \theta_{t-1}$  ▷ Mise à jour
8: end for
```

L'algorithme AdamW a été retenu en raison de sa robustesse sur les problèmes de grande dimension, de sa disponibilité native dans PyTorch et de sa bonne adaptation à un contexte où la dimension de l'espace d'optimisation peut varier. Par ailleurs, le coût élevé d'évaluation de la fonction objectif rend particulièrement avantageuse l'utilisation d'une méthode basée sur les gradients, ceux-ci pouvant être calculés efficacement grâce aux mécanismes de différentiation automatiques de PyTorch. Enfin, les résultats préliminaires obtenus ayant montré une convergence stable et des performances satisfaisantes, cet optimiseur a été conservé pour l'ensemble des expériences.

Avec tout ceci, une fois l'algorithme exécuté nous obtenons les résultats de la FIGURE 18. Comme nous pouvons l'observer sur cette figure, les résultats obtenus dépendent fortement




FIGURE 18 – Comparaison des résultats obtenus avec deux graines différentes.

de l'initialisation de l'algorithme. En effet, bien que le premier nuage généré soit identique pour les deux exécutions, des différences importantes apparaissent rapidement dans les nuages suivants. Nous observons notamment que la première initialisation conduit majoritairement à des nuages fortement concentrés, tandis que la seconde fait émerger des configurations plus variées et présentant une dispersion plus importante des points. Deux initialisations différentes conduisent ainsi à des échantillons finaux sensiblement distincts, alors même qu'ils sont obtenus à l'aide de la même méthode d'optimisation et de la même métrique.

Cependant, un second problème, plus fondamental, apparaît également. En effet, que l'on considère la MMD ou la distance de Wasserstein, un nuage de points dont tous les points sont exactement superposés possède une propriété dégénérée, sa distance à n'importe quel autre nuage ne dépend plus de son cardinal. Autrement dit, deux nuages constitués d'un nombre différent de points mais concentrés en une même position sont indiscernables du point de vue de la métrique utilisée.

Nous sommes alors confrontés à un problème d'identifiabilité. Certaines configurations pourtant distinctes dans l'espace des nuages de points deviennent équivalentes pour le critère d'optimisation, ce qui peut conduire l'algorithme à choisir le nuage de point au hasard parmi tous les nuages dégénéré.

Preuve : Soit $X = \{x_1, \dots, x_n\}$ un nuage de points à n points. Soit $Y = \{y_1, \dots, y_m\}$ un nuage de point à m point aux coordonnées identique. Donc $y_i = y_j \forall i, j \in \llbracket 1, m \rrbracket$. Nous avons

donc

$$\begin{aligned}
 MMD^2(X, Y) &= \frac{1}{N^2} \sum_{i,j} k(x_i, x_j) + \frac{1}{M^2} \sum_{i,j} k(y_i, y_j) - \frac{2}{NM} \sum_{i,j} k(x_i, y_j) \\
 &= \frac{1}{N^2} \sum_{i,j} k(x_i, x_j) + \frac{1}{M^2} \sum_{i,j} k(y_1, y_1) - \frac{2}{NM} \sum_{i,j} k(x_i, y_1) \\
 &= \frac{1}{N^2} \sum_{i,j} k(x_i, x_j) + k(y_1, y_1) - \frac{2}{N} \sum_i k(x_i, y_1)
 \end{aligned}$$

Et pour la distance de Wasserstein rappelons que $C = D(x_i, y_j)$ ou D est la distance euclidienne. Donc nous avons :

$$\begin{aligned}
 W_2^2(X, Y) &= \min_P \left(\sum_{i,j}^{n,m} C_{i,j} P_{i,j} \right) \\
 &= \min_P \left(\sum_{i,j}^{n,m} C_{i,1} P_{i,j} \right) \\
 &= \min_P \left(\sum_i^n C_{i,1} \sum_j^m P_{i,j} \right) \\
 &= \min_P \left(\sum_i^n C_{i,1} \frac{1}{N} \right)
 \end{aligned}$$

Ainsi, pour la distance de Wasserstein comme pour la MMD, un nuage constitué de points tous superposés est entièrement caractérisé par sa position géométrique et non par son cardinal. Le nombre de points présents dans un tel nuage devient donc invisible pour la métrique considérée.

Ce problème provient du fait que nous autorisons plusieurs points d'un même nuage à être exactement superposés. Cependant, cette hypothèse entraîne une conséquence importante. Elle donne, en effet, la possibilité de construire deux nuages de points distincts qui sont pourtant à distance nulle l'un de l'autre pour les métriques que nous avons choisies. Pour s'en convaincre, il suffit de considérer un nuage de points quelconques et de dupliquer chacun de ses points. Les deux nuages obtenus possèdent alors exactement la même répartition de masse dans l'espace. Ils représentent donc la même mesure empirique, ce qui implique que leur distance de Wasserstein ainsi que leur MMD sont nulles.

Alors, deux objets distincts dans l'espace des nuages de points peuvent être considérés comme équivalents par ces métriques. Sous cette modélisation, la distance de Wasserstein et la MMD ne définissent donc plus des distances au sens strict sur l'espace des nuages de points, mais seulement des semi-distances.

Ne souhaitant pour autant pas interdire la présence de points superposés au sein d'un même nuage, nous avons choisi de traiter ce problème différemment. Pour cela, nous ajoutons à la fonction objectif un terme de pénalisation dépendant de l'écart entre le cardinal du nuage en cours d'optimisation et les cardinaux des nuages de points déjà présents dans l'échantillon, que

nous définissons par :

$$pena_{card} = \sum_{i=1}^{\mathcal{M}} |\#Y - \#X_i|$$

Avec Y le nuage de points optimisés et X_i le i -ème nuage de l'ensemble.

Cette pénalisation légère permet de lever le problème d'identifiabilité introduit précédemment. Lorsque plusieurs nuages sont équivalents au sens de la distance de Wasserstein ou de la MMD, l'information portée par leur cardinal permet désormais à l'algorithme de les différencier et d'orienter son choix.

Pour conclure, cette première approche, bien que relativement naïve, permet d'obtenir des échantillons de nuages de points dont la qualité reste satisfaisante. Elle met notamment en évidence la faisabilité d'une construction itérative reposant sur le critère maximin. Toutefois cette méthode présente plusieurs limitations importantes. Tout d'abord, comme nous l'avons montré précédemment, les solutions obtenues dépendent fortement de l'initialisation de l'algorithme. Par ailleurs, cette stratégie devient rapidement coûteuse lorsque la taille de l'échantillon augmente. En effet, l'ajout de chaque nouveau nuage nécessite la résolution de $N_{\max} - N_{\min} + 1$ problèmes d'optimisation afin d'explorer l'ensemble des cardinaux admissibles. De plus, le coût de chacun de ces problèmes augmente au fur et à mesure de la construction de l'échantillon, l'évaluation du critère nécessitant le calcul d'un nombre toujours plus important de distances entre nuages.

Cette approche repose également sur l'hypothèse implicite qu'est de supposer qu'un échantillon optimal de n nuages peut être construit à partir d'un échantillon optimal de $n - 1$ nuages auquel on ajoute simplement un nouvel élément. Rien ne garantit cependant qu'une telle propriété soit vérifiée. Au contraire, l'ajout d'un nouveau nuage peut modifier en profondeur la configuration optimale de l'ensemble, nécessitant potentiellement de repositionner plusieurs nuages déjà sélectionnés. La construction purement séquentielle risque alors d'écarter certaines solutions pourtant meilleures d'un point de vue global. Ainsi, bien que cette approche fournisse des résultats encourageants et constitue un premier point de référence pertinent, son coût computationnel ainsi que son caractère fortement séquentiel limitent son utilisation pratique et la qualité des solutions auxquelles elle peut prétendre.

Modification a partir du LHS

Maintenant que nous disposons d'une méthode permettant de générer simultanément un ensemble de nuages de points à l'aide d'un LHS, ainsi que d'une méthode capable de construire un nuage satisfaisant au mieux le critère maximin au sein d'un échantillon existant, nous avons cherché à combiner ces deux approches afin de tirer parti de leurs avantages respectifs.

En effet, bien que la génération par LHS soit extrêmement rapide, les échantillons obtenus conservent fortement les caractéristiques de la loi utilisée pour leur génération. A l'inverse, la méthode itérative présentée précédemment permet de construire des échantillons davantage adaptés au critère maximin, mais son coût computationnel devient rapidement prohibitif lorsque le nombre de nuages augmente. La complexité de la méthode croît en effet avec la taille de l'échantillon, puisque chaque nouveau nuage doit être optimisé en tenant compte de

l'ensemble des nuages déjà présents.

Par ailleurs, nous avons vu que le caractère *space-filling* des échantillons construits de manière strictement séquentielle restait discutable. En effet, le fait d'ajouter à chaque étape le nuage le plus éloigné possible des nuages déjà présents ne garantit pas que ce nouveau nuage améliore réellement la qualité globale de l'échantillon. Rien n'assure notamment qu'un ensemble optimal de n nuages puisse être obtenu en ajoutant simplement un nuage à un ensemble optimal de $n - 1$ nuages. Cette construction progressive ne fournit donc aucune garantie théorique sur le caractère réellement *space-filling* de la solution finale.

Nous avons donc adopté une approche hybride. Dans un premier temps, un échantillon initial est généré à l'aide du LHS. Ensuite, à chaque itération, nous identifions la paire de nuages dont la distance est la plus faible. Parmi ces deux nuages, nous sélectionnons celui dont la seconde plus petite distance aux autres éléments de l'échantillon est la plus faible, puis nous le retirons temporairement.

Nous cherchons alors à le remplacer par un nouveau nuage obtenu à l'aide de la procédure d'optimisation décrite dans la méthode itérative précédente. L'objectif est de maximiser sa distance minimale à l'ensemble des nuages restants.

Le nuage candidat n'est toutefois accepté que si sa distance minimale est strictement supérieure à celle du nuage qu'il remplace. Cette précaution est nécessaire car la fonction objectif associée aux distances de Wasserstein ou à la MMD n'est pas convexe. L'algorithme d'optimisation peut alors converger vers un optimum local ou, lorsque l'échantillon est déjà proche d'un optimum, produire une solution de qualité équivalente voire légèrement moins bonne en raison des erreurs numériques et des critères d'arrêt.

Lorsqu'un candidat est accepté, il remplace définitivement le nuage retiré. Dans le cas contraire, une nouvelle optimisation est lancée à partir d'une initialisation différente. Il est toutefois possible qu'un même nuage soit sélectionné plusieurs fois consécutivement pour être optimisé. Cette situation peut se produire aussi bien lorsqu'aucune amélioration n'est trouvée que lorsque le nouveau nuage obtenu améliore légèrement le critère sans pour autant cesser d'être l'élément limitant de l'échantillon. Dans les deux cas, cela indique que l'algorithme consacre de nombreuses itérations à l'amélioration d'un même nuage pour des gains de plus en plus faibles.

Afin d'éviter un temps de calcul excessif, nous comptabilisons le nombre de fois consécutives où un même nuage est désigné pour être réoptimisé. Lorsque ce nombre atteint six, nous considérons que l'échantillon est suffisamment proche d'un optimum et nous arrêtons l'algorithme.

Ce procédé permet d'obtenir les résultats présentés à la FIGURE 19, où l'on compare l'échantillon initial obtenu par LHS à l'échantillon final après optimisation.




FIGURE 19 – Comparaison entre les nuages initiaux et finaux de l’algorithme

Nous pouvons constater qu’une partie importante des nuages de points finaux reste inchangée par rapport à l’initialisation. Ce comportement s’explique par la structure même de l’algorithme. En effet, à chaque itération, seul le nuage associé à la plus faible distance minimale est sélectionné pour être modifié. Certains nuages, suffisamment éloignés de leurs voisins dès l’initialisation, ne sont donc jamais désignés comme candidats à l’optimisation et restent inchangés tout au long de l’exécution de l’algorithme.

Cette observation est confirmée par la FIGURE 20, qui représente l’évolution de la distance minimale au cours de l’optimisation. Les numéros affichés le long de l’axe des abscisse correspondent aux indices des nuages modifiés à chaque étape. On constate alors que seuls quelques nuages sont réoptimisés de manière récurrente, tandis que d’autres ne sont jamais sélectionnés.

Nous observons donc que, pour cette initialisation, seuls les nuages 0, 6, 7 et 8 ont été modifiés au cours de l’optimisation. Comme nous pouvions le pressentir en observant les résultats de la figure précédente, les autres nuages demeurent inchangés entre l’entrée et la sortie de l’algorithme.

Bien qu’une grande partie des nuages reste inchangée, les nuages étant effectivement optimisés présentent des comportements variés. Comme pour la méthode itérative précédente, certaines solutions dégénérées peuvent apparaître. C’est notamment le cas du nuage 8, dont l’ensemble des points finit par se concentrer en une unique position. Néanmoins, ce phénomène n’est pas systématique. Le nuage 6 illustre au contraire qu’il est possible d’améliorer un nuage sans que celui-ci ne s’effondre sur lui-même.

Le fait que tous les nuages ne soient pas soumis à une étape d’optimisation n’est pas nécessairement problématique. En effet, l’échantillon initial étant obtenu à partir d’un LHS cherchant




FIGURE 20 – Evolution de la distance minimal entre deux nuage de points

déjà à répartir au mieux les nuages dans l'espace considéré, certains d'entre eux peuvent être suffisamment éloignés des autres pour ne jamais être identifiés comme limitants par l'algorithme.

En revanche, cette propriété possède également une contrepartie importante. Puisque seule une partie des nuages est effectivement optimisée, il demeure impossible d'obtenir une garantie théorique sur la qualité de la solution finale. Cette approche permet néanmoins de corriger partiellement certaines limitations des méthodes dont elle est issue. En particulier, elle réduit l'influence de la loi utilisée pour générer l'échantillon initial par LHS et atténue le caractère strictement séquentiel de la méthode itérative précédente, où chaque nouveau nuage était construit à partir de l'échantillon déjà existant.

Ces améliorations restent toutefois limitées. La méthode demeure sensible à l'initialisation et son coût computationnel continue d'augmenter rapidement avec la dimension du problème. Elle doit donc davantage être vue comme un compromis entre les deux approches précédentes que comme une solution définitive à leurs limitations, puisqu'elle conserve encore une partie importante de leurs défauts respectifs.

Annexe 3 : softmax

La première méthode que nous avons explorée repose sur l'utilisation d'une fonction softmax définie par :

$$\sigma(\mathbf{w})_j = \frac{e^{w_j}}{\sum_{k=1}^n e^{w_k}} \quad \text{avec } \{w_1, \dots, w_n\} \text{ les poids libres appartenant à } \mathbb{R}.$$


Le choix de cette fonction est naturel dans notre contexte, puisqu'elle est couramment utilisée pour optimiser sur des simplexes². Elle garantit en effet la positivité des poids ainsi que le fait qu'ils se somment à 1, ce qui correspond précisément à la contrainte que nous souhaitons imposer à nos nuages de points pondérés. Toutefois, nous avons rapidement constaté que cette approche n'était pas parfaitement adaptée à notre objectif. En effet, nous cherchons en réalité à faire émerger une certaine parcimonie dans les poids. À terme, nous souhaiterions que les poids associés aux points inactifs soient proches de zéro tandis que les points actifs possèdent des poids relativement homogènes, de l'ordre de $\frac{1}{N}$ où N désigne le nombre de points actifs du nuage considéré. En effet, une telle séparation entre points actifs et inactifs permettrait alors de supprimer les poids associés aux nuages et d'éliminer les points de poids quasiment nul sans modifier significativement les distances entre nuages de points.

La première difficulté que nous rencontrons avec cette méthode est le choix des points actifs en fin d'optimisation. Nous voulons alors conserver les points associés au poids les plus grands, afin de conserver l'essentiel de la masse du nuage. Pour parvenir à faire cela de manière cohérente, nous avons alors étudié deux stratégies différentes.

La première approche consiste à trier les poids du plus grand au plus petit puis à considérer comme actifs les points associés aux poids nécessaires pour dépasser une certaine masse cumulée que nous avons fixés à $1 - \frac{1}{N_{\max}+1}$. Cette approche, que l'on a nommé cumsum, présente cependant plusieurs inconvénients. Le premier étant que rien ne garantit que les poids des points retenus soient suffisamment importants. Il est alors possible de conserver des points portant une masse très faible, ce qui peut fortement perturber le résultat obtenu après post-traitement. Par ailleurs, cette méthode n'offre aucun contrôle direct sur le respect du nombre minimal de points imposé, ce qui pose également un important problème.

Nous avons alors envisagé une seconde approche reposant sur l'utilisation d'un seuil fixe. Un point est alors considéré comme actif lorsque son poids dépasse ce seuil, nous avons alors choisi comme seuil $\frac{1}{N_{\max}+1}$ afin qu'il soit possible que tous les points soient actifs simultanément. Bien que plus simple, cette méthode souffre également de plusieurs défauts. Un de ceux-ci étant qu'un point dont le poids est légèrement inférieur au seuil peut être désactivé alors même qu'il porte une part importante de la masse. Inversement, un des points sélectionné peut porter la grande majorité du poids parmi les points actifs et ainsi déséquilibrer grandement le nuage que nous obtenons après le poste traitement. Enfin, même ainsi, rien ne nous garantit non plus de respecter la borne inférieure que nous donne $N_{\min}$.

Une partie de ces difficultés apparaît clairement lorsque l'on observe la FIGURE 21. Alors que nous avons fixé $N_{\min} = 11$ et $N_{\max} = 20$, aucune des deux méthodes ne parvient à respecter correctement cet intervalle. Cette observation confirme les limites évoquées précédemment.



(a) Repartition obtenue à l'aide de notre première méthode (b) Repartition obtenue à l'aide de notre seconde méthode

FIGURE 21 – Comparaison des distribution des cardinaux en fonction du critère de selection des points choisi pour 25 nuage de points

La méthode par seuil est la plus affectée par ce phénomène puisque seuls 5 nuages parmi les 25 générés possèdent effectivement un nombre de points compris entre $N_{\min}$ et $N_{\max}$. La méthode *cumsum* respecte davantage ces contraintes mais présente un autre biais important : elle favorise fortement un unique cardinal. Dans l'exemple présenté, la majorité des nuages possède ainsi 18 points actifs, ce qui conduit à une répartition très déséquilibrée des cardinaux au sein de l'échantillon.

Même si rien, à ce stade, ne permet d'affirmer qu'un échantillon *space-filling* optimal devrait présenter une distribution uniforme de ses cardinaux, une telle concentration sur quelques valeurs apparaît peu souhaitable en pratique. En effet, l'un des intérêts de travailler avec des nuages de points de cardinal variable est précisément de pouvoir explorer une grande diversité de géométries induite par ceci. Or lorsque la majorité des nuages possède un cardinal identique ou très proche, une partie importante de cette diversité disparaît.

Ainsi, indépendamment de la question du caractère optimal de la distribution des cardinaux, ces résultats suggèrent qu'il est nécessaire d'introduire un mécanisme permettant de mieux contrôler leur répartition au sein de l'échantillon. C'est pour cela que nous avons introduit la pénalisation suivante, visant à favoriser une répartition plus uniforme du nombre de nuages pour chaque cardinal admissible :

$$pena_j = \sum_{i=N_{\min}}^{N_{\max}} \left| \frac{\mathcal{M}}{N_{\max} - N_{\min} + 1} - nbp_i \right|$$

où nbp_i désigne le nombre de nuages possédant i points actifs à l'itération j .

L'intérêt de cette formulation est qu'elle permet de remplacer facilement la distribution uniforme recherchée par n'importe quelle autre distribution cible si cela s'avère nécessaire.

Cependant, cette pénalisation fait apparaître une nouvelle difficulté. Afin de pouvoir l'utiliser dans le cadre d'une descente de gradient, il est nécessaire de disposer à chaque itération d'une estimation dérivable du nombre de points actifs dans chaque nuage. Des méthodes de type *soft count*, telles que :

$$SoftCount(X, c) = \sum_{i=1}^M e^{-t\|x_i - c\|^2},$$

où t contrôle la précision de l'approximation, permettent de répondre partiellement à ce problème.

La difficulté provient cependant moins du comptage lui-même que de son utilisation ultérieure. En effet, notre pénalisation nécessite non seulement d'estimer le nombre de points actifs de chaque nuage, mais également le nombre de nuages possédant un cardinal donné. Nous sommes ainsi amenés à effectuer un comptage sur une quantité qui est déjà une approximation différentiable. Bien que cela reste théoriquement possible, la qualité de l'approximation se dégrade rapidement. À l'inverse, un comptage exact conduirait à l'utilisation d'opérations non différentiables, incompatibles avec notre algorithme d'optimisation.

Ainsi, bien que la paramétrisation par softmax fournisse naturellement des poids valides et soit tout à fait adaptée lorsqu'il s'agit uniquement d'optimiser des mesures de probabilité, elle s'est révélée peu adaptée à notre objectif de contrôle du cardinal des nuages. C'est pour cette raison que nous avons finalement choisi d'explorer une seconde approche fondée sur l'utilisation d'une fonction sigmoïde, présentée dans la section suivante.

Annexe 4 : Preuve proposition 2

Preuve : (somme des sigmoïde proche du nombre d'élément positif de w)

Soit $W \in R^n$ et soit $\delta \in R$ tel que $\forall i \ |w_i| \geq \delta > 0$. Nous posons $\sigma : R \rightarrow [0, 1]$ la fonction sigmoïde. Nous avons donc :

Si $w_i \geq \delta > 0$ alors

$$\begin{aligned} \sigma(w_i) &\geq \sigma(\delta) \\ \Leftrightarrow \frac{1}{1 + e^{-w_i}} &\geq \frac{1}{1 + e^{-\delta}} = 1 - \frac{1}{1 + e^{\delta}} \\ \Rightarrow 1_{w_i > 0} - \sigma(w_i) &= 1 - \sigma(w_i) \leq \frac{1}{1 + e^{\delta}} \end{aligned}$$

Si $w_i \leq -\delta < 0$ alors

$$\begin{aligned} \sigma(w_i) &\leq \sigma(\delta) \\ \Leftrightarrow \frac{1}{1 + e^{-w_i}} &\leq \frac{1}{1 + e^{\delta}} \\ \Rightarrow \sigma(w_i) - 1_{w_i > 0} &= \sigma(w_i) \leq \frac{1}{1 + e^{\delta}} \end{aligned}$$

Donc nous avons pour tout i que :

$$\begin{aligned} \|1_{w_i > 0} - \sigma(w_i)\| &\leq \frac{1}{1 + e^{\delta}} \\ \Rightarrow \sum_{i=1}^n \|1_{w_i > 0} - \sigma(w_i)\| &\leq n \frac{1}{1 + e^{\delta}} \\ \Rightarrow \left\| \sum_{i=1}^n 1_{w_i > 0} - \sum_{i=1}^n \sigma(w_i) \right\| &\leq n \frac{1}{1 + e^{\delta}} \\ \Rightarrow \left\| \sum_{i=1}^n 1_{w_i > 0} - \sum_{i=1}^n \sigma(w_i) \right\| &\leq n \frac{1}{1 + e^{\delta}} \quad \blacksquare \end{aligned}$$

Où $\sum_{i=1}^n 1_{w_i > 0}$ correspond exactement au nombre de point actif et $\sum_{i=1}^n \sigma(w_i)$ correspond à l'estimation continue du nombre de points actif.

Annexe 5 : nuage obtenue via maximin sans pénalisation




FIGURE 22 – Reste de l'échantillon de nuage de points généré à l'aide du critère maximin sans pénalisation

Annexe 6 : Preuve proposition 3 **Preuve :** Soit $(x_1, \dots, x_n) \in \mathbb{R}$. Soit $M = \min_{i \in \llbracket 1, n \rrbracket} (x_i)$. Alors

$$\begin{aligned} \sum_{i=1}^n e^{-tx_i} &= e^{-tM} \sum_{i=1}^n e^{-t(x_i-M)} \\ \Rightarrow LSE(-tx) &= -tM + \log\left(\sum_{i=1}^n e^{-t(x_i-M)}\right) \\ \Rightarrow \frac{1}{-t} LSE(-tx) &= M - \frac{1}{t} \log\left(\sum_{i=1}^n e^{-t(x_i-M)}\right) \end{aligned}$$

Or $0 < e^{-t(x_i-M)} \leq 1$ et nous avons égalité à gauche pour au moins l'un des x_i . Donc

$$\begin{aligned} 1 &< \sum_{i=1}^n e^{-t(x_i-M)} \leq n \\ \Rightarrow 0 &< \log\left(\sum_{i=1}^n e^{-t(x_i-M)}\right) \leq \log(n) \\ \Rightarrow -\frac{\log(n)}{t} &\leq -\frac{1}{t} \log\left(\sum_{i=1}^n e^{-t(x_i-M)}\right) < 0 \\ \Rightarrow M - \frac{\log(n)}{t} &\leq M - \frac{1}{t} \log\left(\sum_{i=1}^n e^{-t(x_i-M)}\right) < M \\ \Rightarrow M - \frac{\log(n)}{t} &\leq \frac{1}{-t} LSE(-tx) < M \end{aligned}$$

Donc LSE est bien une approximation lisse du minimum. ■

Annexe 7 : nuage obtenue via maximin avec parametre de répulsion




FIGURE 23 – Reste de l'échantillon de nuage de points généré à l'aide du critère maximin avec parametre de répulsion

Annexe 8 : nuage obtenue via maximin avec repulson adaptative




FIGURE 24 – Reste de l'échantillon de nuage de points généré à l'aide du critère maximin avec répulsion adaptative

Annexe 9 : nuage obtenue via jln méthode




FIGURE 25 – Reste de l'échantillon de nuage de points généré à l'aide de la méthode jln

Annexe 10 : Comparaison distance







FIGURE 26 – Nuage initial utiliser dans nos méthodes d'échantillonnage




(a) MMD batch 1



(b) Wasserstein batch 1




(c) MMD batch 2




(d) Wasserstein batch 2


FIGURE 27 – Comparaison entre les nuages obtenu en utilisant la MMD à gauche et la distance de Wassestein à droite, avec la méthode maximin sans pénalisation




(a) MMD batch 3



(b) Wasserstein batch 3




(c) MMD batch 4




(d) Wasserstein batch 4


FIGURE 28 – Comparaison entre les nuages obtenu en utilisant la MMD à gauche et la distance de Wassestein à droite, avec la méthode maximin sans pénalisation




(a) MMD batch 1



(b) Wasserstein batch 1




(c) MMD batch 2




(d) Wasserstein batch 2


FIGURE 29 – Comparaison entre les nuages obtenu en utilisant la MMD à gauche et la distance de Wassestein à droite, avec la méthode maximin avec parametre de répulsion




(a) MMD batch 3



(b) Wasserstein batch 3




(c) MMD batch 4




(d) Wasserstein batch 4


FIGURE 30 – Comparaison entre les nuages obtenu en utilisant la MMD à gauche et la distance de Wassestein à droite, avec la méthode maximin avec parametre de répulsion




(a) MMD batch 1



(b) Wasserstein batch 1




(c) MMD batch 2




(d) Wasserstein batch 2


FIGURE 31 – Comparaison entre les nuages obtenu en utilisant la MMD à gauche et la distance de Wassestein à droite, avec la méthode maximin avec parametre de répulsion adaptatif




(a) MMD batch 3



(b) Wasserstein batch 3




(c) MMD batch 4




(d) Wasserstein batch 4


FIGURE 32 – Comparaison entre les nuages obtenu en utilisant la MMD à gauche et la distance de Wassestein à droite, avec la méthode maximin avec parametre de répulsion adaptatif




(a) MMD batch 1



(b) Wasserstein batch 1




(c) MMD batch 2




(d) Wasserstein batch 2


FIGURE 33 – Comparaison entre les nuages obtenu en utilisant la MMD à gauche et la distance de Wassestein à droite, avec la méthode jln




(a) MMD batch 3



(b) Wasserstein batch 3



(c) MMD batch 4



(d) Wasserstein batch 4

FIGURE 34 – Comparaison entre les nuages obtenu en utilisant la MMD à gauche et la distance de Wassestein à droite, avec la méthode jln